



# **UNIVERSITÀ DEGLI STUDI** **DI MILANO BICOCCA**

*CORSO DI INTRODUZIONE ALLE SERIE STORICHE ECONOMICHE M*

## **ANALISI COMPARATIVA DEI LIVELLI DI INQUINAMENTO IN UN'AREA URBANA E UN'AREA AEROPORTUALE: BERGAMO CITTÀ VS MILANO MALPENSA**

A cura di  
Tarantini Martina Matr. 905790 ([m.tarantini5@campus.unimib.it](mailto:m.tarantini5@campus.unimib.it))

Anno Accademico 2024-2025

# INDICE

|                                                                 |    |
|-----------------------------------------------------------------|----|
| 1. Introduzione .....                                           | 3  |
| 2. Analisi esplorativa.....                                     | 4  |
| 2.1. Variabile NO <sub>2</sub> (misurata in $\mu g/m^3$ ) ..... | 4  |
| 2.2. Variabile PM <sub>10</sub> (misurata in $\mu g/m^3$ )..... | 13 |
| 3. Decomposizione delle serie storiche .....                    | 20 |
| 4. Regressione .....                                            | 23 |
| 5. Modellistica.....                                            | 26 |
| 5.1. Modellistica per NO <sub>2</sub> a Bergamo .....           | 27 |
| 5.2. Modellistica per NO <sub>2</sub> a Malpensa .....          | 28 |
| 5.3. Modellistica per PM <sub>10</sub> a Bergamo .....          | 30 |
| 5.4. Modellistica per PM <sub>10</sub> a Malpensa .....         | 31 |
| 6. Conclusione .....                                            | 32 |

## 1. Introduzione

L'elaborato ha l'obiettivo di mettere a confronto il livello di inquinamento presente in due diverse aree: una cittadina, in prossimità del centro città di Bergamo, e una aeroportuale, nei pressi dell'aeroporto di Milano Malpensa.

L'analisi di serie storiche proposta di seguito vuole rispondere a specifiche domande di ricerca, tra cui:

- La presenza di un aeroporto comporta livelli di inquinamento atmosferico più elevati rispetto a quelli rilevati in un contesto urbano?
- Gli inquinanti sono influenzati da variabili meteorologiche?
- Qual è stato l'impatto della pandemia da COVID-19 sull'inquinamento nelle due aree considerate?

È necessario, infatti, ricordare la chiusura di scuole e uffici, a seguito di misure di lockdown entrate in vigore nel 2020, e una maggiore diffusione dello smart working, generando così una diminuzione del traffico cittadino. Per quel che riguarda, invece, l'area di Malpensa, oltre al calo dei voli, si è registrata anche una diminuzione degli spostamenti dei mezzi di supporto e del traffico indotto.

Il livello di inquinamento è stato monitorato attraverso due centraline fisse, rispettivamente collocate a Bergamo, in Via Meucci, e a Ferno, in Via Di Dio. Nel report di seguito, per spostare il focus sul contrasto città/aeroporto, verranno indicate semplicemente come Bergamo e Malpensa. I dati analizzati sono mensili e si riferiscono al periodo compreso tra gennaio 2016 e novembre 2022 (per un totale di 83 osservazioni per stazione), e sono stati raccolti da [ARPA Lombardia](#) (Agenzia Regionale per la Protezione dell'Ambiente della Lombardia), un ente pubblico che monitora la qualità dell'aria per supportare le scelte politiche e informare i cittadini sull'inquinamento atmosferico, fattore cruciale per la tutela della salute e dell'ambiente.

Le centraline monitorano 24 ore su 24 le concentrazioni dei principali inquinanti atmosferici come  $\text{NO}_x$ ,  $\text{SO}_2$ ,  $\text{CO}$ ,  $\text{O}_3$ ,  $\text{PM}_{10}$ ,  $\text{PM}_{2.5}$  e benzene. Il dataset conteneva, però, informazioni solo su quattro di questi:

- *$\text{NO}_2$ , biossido di azoto*: gas proveniente per lo più da veicoli, industrie, centrali elettriche e impianti di riscaldamento, infatti è un inquinante stagionale che registra i valori più elevati nei mesi più freddi.
- *$\text{NO}_x$ , sigla per indicare collettivamente tutti gli ossidi di azoto e le loro miscele*: include il monossido di azoto ( $\text{NO}$ ), il biossido di azoto ( $\text{NO}_2$ ) già definito sopra, l'ossido di diazoto ( $\text{N}_2\text{O}$ ) e altri composti, prodotti da processi di combustione ad alta temperatura per ossidazione dell'azoto atmosferico.
- *$\text{O}_3$ , ozono*: gas che, nonostante protegga dalle radiazioni ultraviolette dannose, è un inquinante prodotto da una reazione chimica tra la luce del sole, i gas organici ed ossidi di azoto che vengono rilasciati da diverse fonti, tra cui auto e centrali elettriche; costituisce il tipico inquinamento estivo detto smog fotochimico.
- *$\text{PM}_{10}$ , particolato* (acronimo inglese "*Particulate Matter smaller than 10 micron*"): polveri più sottili e dannose, che racchiudono tutte le sostanze presenti nell'atmosfera allo stato solido o liquido, con diametro inferiore o uguale ai 10 micrometri. È un inquinante molto diverso da tutti gli altri, perché è una miscela di particelle di proprietà diverse e non una specifica entità chimica.

Nel dataset analizzato, ciascuno dei quattro inquinanti sopra descritti rappresenta una variabile distinta, di tipo quantitativo continuo, con medesima unità di misura,  $\mu\text{g}/\text{m}^3$ .

Ulteriori variabili presenti nel dataset sono:

- *$\text{ARPA\_ID\_staz}$* : variabile ordinale, che rappresenta un codice identificativo ARPA per la stazione considerata e proprio per questo è un numero assoluto, senza unità di misura.
- *$\text{Cod\_staz}$* : variabile ordinale che indica un codice della stazione.
- *$\text{Nome\_staz}$* : variabile nominale che indica il nome della stazione.
- *$\text{Data}$  (in formato mensile)*: variabile temporale che indica il mese e l'anno di riferimento.

In ultimo, sono presenti anche tre variabili quantitative continue meteorologiche: fondamentali in riferimento all'inquinamento atmosferico, perché regolano la velocità con cui gli inquinanti vengono trasportati e si disperdono nell'aria oppure vengono portati al suolo. Inoltre, influenzano anche la velocità

di alcune reazioni chimiche che formano in atmosfera inquinanti secondari (come l'ozono). Sono rispettivamente:

- *Temperatura*: misurata in °C.
- *Umidità relativa*: quantità di vapore acqua presente nell'aria rispetto al massimo che l'aria può contenere. Se è alta, l'aria è più umida e calda, e viene misurata in %.
- *Pioggia\_cum*: è la quantità di pioggia (e neve) caduta nell'intero mese, misurata in mm.

Inoltre, è importante anche ricordare che, secondo i criteri dell'Agenzia Europea per l'Ambiente (EEA), le stazioni di misura della qualità dell'aria vengono classificate a seconda della tipologia della stazione, dell'area e delle caratteristiche della zona: entrambe le stazioni prese in considerazione in questo elaborato vengono classificate come UB, cioè sono stazioni in aree urbane (U) e di fondo (B - background), cioè ubicate non direttamente in prossimità di una particolare fonte di emissione, ma risentono del contributo integrato di tutte le fonti. Questa classificazione comune le rende perfettamente comparabili.

## 2. Analisi esplorativa

Dal momento che l'obiettivo dell'elaborato è il confronto tra le due centraline, l'analisi esplorativa (EDA) seguente si concentrerà su due specifici inquinanti del dataset originale, NO<sub>2</sub> e PM<sub>10</sub>, utilizzando per ciascuno tutti gli strumenti analitici a nostra disposizione. Più precisamente, si procederà con:

- Grafico delle serie storiche: fondamentale per catturare alcune caratteristiche essenziali, come la presenza di componenti non osservabili, il grado di persistenza e la stazionarietà.
- Analisi della distribuzione dei dati: si impiegano strumenti grafici della statistica descrittiva come l'istogramma e il box-whisker plot (a complemento) e strumenti analitici come i test di normalità (test di Bera-Jarque, test di Shapiro-Wilk e test di Kolmogorov-Smirnov) per capire quanto i dati si discostino dalla normalità, che è il nostro riferimento.
- Gestione di possibili outlier (valori anomali): problema risolvibile con la regola del  $3\sigma$ , il filtro di Hampel oppure la regola del box-plot.
- Analisi della persistenza e autocorrelazione dei dati: gli strumenti grafici a disposizione sono il correlogramma (ACF) e il correlogramma parziale (PACF), seguiti dai lag-plot e da strumenti analitici come il test di Portmanteau, nelle due versioni di Box-Pierce e Ljung-Box.
- Eventuale trasformazione di Box-Cox: da applicare se la variabile non risulta normale.
- Analisi di non stazionarietà: sfruttando il test di Dickey-Fuller aumentato (Test ADF)
- Eventuale detrendizzazione, differenziazione o destagionalizzazione: da svolgere qualora nel punto precedente la serie risulti caratterizzata rispettivamente da un trend deterministico, un trend stocastico o una stagionalità deterministica.


Questo è un ordine indicativo, ma a seconda dei risultati delle analisi, ci riserviamo la possibilità di eseguire le operazioni in un ordine diverso.

### 2.1. Variabile NO<sub>2</sub> (misurata in $\mu\text{g}/\text{m}^3$ )

#### a) Grafico

Le serie storiche relative al comportamento dell'inquinante NO<sub>2</sub> (biossido di azoto) presentano un andamento abbastanza simile nei pressi dell'aeroporto di Malpensa e della città di Bergamo. È evidente una forte stagionalità comune: ci sono dei picchi positivi invernali e concentrazioni più basse in estate. Le motivazioni sono principalmente due:

- Fattori climatici: l'inversione termica invernale e le basse temperature fanno sì che l'aria fredda si accumuli al suolo "intrappolando" gli inquinanti ed evitandone così la dispersione.



D'altra parte, le temperature elevate e la maggiore ventilazione dei mesi estivi favoriscono il rimescolamento dell'aria e la conseguente dispersione degli inquinanti.

- Emissioni: in inverno c'è un maggiore aumento dell'uso dei combustibili, ad esempio per il riscaldamento domestico, da sommare alle emissioni del traffico veicolare.

Spostando il focus invece sul confronto tra le due stazioni, possiamo notare che i livelli di inquinante sono più elevati a Bergamo, soprattutto a partire da marzo 2017. La differenza è evidente soprattutto in corrispondenza dei picchi invernali: questo può essere dovuto dal fatto che la centralina di Bergamo è posta in una via del centro città; quindi, l'impatto del traffico veicolare e soprattutto del riscaldamento è notevole nel centro urbano. D'altra parte, l'aeroporto di Milano Malpensa, invece, viene monitorato attraverso la centralina di Ferno, ben lontana dal centro di una grande provincia, che quindi non risente di questi aspetti. Lo stesso fenomeno è riscontrabile d'estate: però, solo a partire dal 2020, i livelli più bassi sono stati raggiunti in corrispondenza di Malpensa, segno sempre di una notevole importanza del traffico urbano nei pressi di Bergamo.

In particolare, nel 2022, l' $\text{NO}_2$  ha raggiunto il suo massimo a Bergamo con valori oltre i  $60\mu\text{g}/\text{m}^3$ , e nello stesso anno, a Malpensa non ha raggiunto neanche i  $40\mu\text{g}/\text{m}^3$ .

Bisogna prestare però attenzione anche ai doppi picchi presenti nella serie storica di Bergamo, in particolare nel triennio 2017-2019: hanno intensità diverse e questo potrebbe suggerire l'influenza di fattori esogeni e quindi una stagionalità meno prevedibile e non deterministica.


Oggetto di attenzione è quello che accade in corrispondenza del biennio 2020-2021: c'è, infatti, un calo anomalo, oggi spiegabile con la pandemia da COVID-19 e il conseguente lockdown. Nonostante il crollo sia evidente nei pressi di entrambe le centraline, tenendo conto dei valori degli anni precedenti e posteriori, la pandemia sembra aver impattato particolarmente (in questo contesto, in modo positivo) su Bergamo: le misure drastiche di chiusura di attività produttive e la conseguente riduzione del traffico veicolare hanno ridotto sensibilmente il livello di inquinante  $\text{NO}_2$ , tanto da generare una diminuzione dell'inquinamento per alcuni mesi (è possibile notare un andamento a "U" piuttosto che a "V" in corrispondenza del 2020), con una ripresa fondamentale poi nel 2022, quando le restrizioni locali sono state per lo più eliminate.

In realtà, però, da una più attenta analisi emerge che i valori dell' $\text{NO}_2$  erano già in diminuzione dall'inizio del 2020, infatti il picco invernale è molto più basso, quindi molto prima che entrassero in vigore le misure di lockdown: c'era già quindi una generale tendenza decrescente dell'inquinamento e una tendenza crescente al miglioramento della qualità dell'aria. Le motivazioni possono essere riscontrabili nell'introduzione sul mercato di auto con emissioni specifiche via via sempre più inferiori. Il picco più elevato, invece, in corrispondenza del 2022 potrebbe essere legato ad un inverno freddo con minori precipitazioni (infatti a dicembre 2021 riscontriamo un valore di piogge cumulate pari a 17 mm contro 107 mm e 184 mm rispettivamente di dicembre 2019 e 2020).

Nonostante l'arco temporale sia relativamente breve (sette anni), possiamo sovrapporre alle serie storiche una funzione a gradini che rappresenta la media (calcolata annualmente): può essere uno strumento utile per verificare la presenza di un trend, perché fornisce un quadro generale per capire se c'è un andamento crescente o decrescente di anno in anno.

Sicuramente dalla serie storica di Bergamo, si può notare un livello medio piuttosto stabile: c'è un leggero calo nel biennio 2018-2019, seguito dal calo netto molto evidente del 2020 (COVID-19), ma con conseguente ripresa già nel 2021 e una stabilizzazione continua. Per

Malpensa, invece, la media subisce una discesa graduale dal 2016 ad oggi: l'ultimo calo però facilmente percettibile lo si riscontra nel 2020 (anche se non netto come a Bergamo, come già commentato precedentemente), mentre nel 2021 e nel 2022 i livelli sembrano rimasti pressoché simili. Sembra quindi esserci un trend decrescente, confermato anche dai picchi positivi che raggiungono livelli via via inferiori.




Questo può essere spiegato da alcuni possibili miglioramenti nelle tecnologie di trasporto e politiche di sostenibilità che si stanno implementando.


Entrambe le serie sono quindi non stazionarie, soprattutto a causa di una forte componente stagionale. Questo porta alla necessità di alcune trasformazioni prima di poter impiegare alcune tipologie di modelli. In particolare, la serie di Malpensa presenta anche un trend di lungo periodo, visibile attraverso la media, che non rimane mai costante durante l'intero arco temporale. D'altra parte, invece, sono serie persistenti: non si passa da un valore ad un altro in modo casuale, infatti il livello della serie dura per un certo periodo prima di modificarsi. Sicuramente un'analisi più approfondita attraverso strumenti specifici permette di dare risposte maggiormente accurate.

Quindi, dai grafici, si può concludere che, per l'inquinante  $\text{NO}_2$ , c'è un forte andamento stagionale, dovuto al clima e la situazione a Bergamo è notevolmente peggiore rispetto alla situazione di Malpensa, con media annuali sempre più elevate. Nonostante questo, però, in ambedue le centraline non si raggiunge il valore limite annuale di  $40 \mu\text{g}/\text{m}^3$  che rappresenta la soglia di allarme, oltre la quale sussistono rischi per la salute umana e necessitano di interventi immediati. Il livello raccomandato dall'OMS di  $\text{NO}_2$  è, invece,  $10 \mu\text{g}/\text{m}^3$ , da cui ci si discosta ancora notevolmente sia a Bergamo che a Milano Malpensa.

#### b) Distribuzione dei dati



Dall'istogramma sembrerebbe che la variabile  $\text{NO}_2$ , in corrispondenza della centralina di Bergamo, non segua una distribuzione normale; infatti, la curva della densità kernel non si sovrappone con la curva teorica di una gaussiana. Una densità maggiore è presente soprattutto in corrispondenza di valori più bassi di  $\text{NO}_2$ , segno di una asimmetria positiva, cosa confermata anche dal box-plot, che presenta una coda a destra molto più lunga, rispetto a quella di sinistra e una mediana attorno  $26 - 27 \mu\text{g}/\text{m}^3$ . Questo in realtà era abbastanza atteso: abbiamo, infatti, sottolineato precedentemente come l'inquinante  $\text{NO}_2$  riesca a stare sempre sotto la soglia di allarme fissata a  $40 \mu\text{g}/\text{m}^3$ , e quindi ci sia una maggiore frequenza dei dati al di sotto di quel valore. Inoltre, il box-plot non evidenzia la presenza di outlier.



Anche i dati raccolti nei pressi di Malpensa presentano una forte asimmetria positiva, evidente sia dall'istogramma (valori più bassi di  $\text{NO}_2$  raggiungono densità più elevate), ma soprattutto dal box-plot che presenta un lungo baffo a destra e una mediana in corrispondenza di valori pari a  $21 - 22 \mu\text{g}/\text{m}^3$ . Anche in questo caso, il box-plot non evidenzia outlier.

Anche qua è possibile fare confrontare le due distribuzioni: sono entrambe asimmetriche positive, ma l'asimmetria dei dati di Malpensa è maggiore; infatti, i valori di  $\text{NO}_2$  sono notevolmente più bassi.

Questi risultati possono essere confermati tramite alcuni test di normalità (test parametrico di Bera-Jarque, test non parametrico di Shapiro-Wilk e test non parametrico di Kolmogorov-Smirnov), che testano l'ipotesi nulla  $H_0$ : i dati sono distribuiti normalmente, contro l'ipotesi alternativa  $H_1$ : i dati non seguono una distribuzione normale.

Nella tabella seguente presentiamo i valori dei p-value di tutti e tre i test, in corrispondenza delle due centraline. Si ricorda che si rifiuta l'ipotesi nulla quando il p-value è minore o uguale al livello di significatività (di norma,  $\alpha = 5\%$ ). Per comodità, in tutte le tabelle presenti in questo report, utilizzeremo \* per indicare un risultato debolmente significativo (rifiuto  $H_0$  al 10%); \*\* per indicare un risultato significativo (rifiuto  $H_0$  al 5%); \*\*\* per indicare un risultato altamente significativo (rifiuto  $H_0$  all'1%).

| $NO_2$   | Test di Bera-Jarque | Test di Shapiro-Wilk | Test di Kolmogorov-Smirnov |
|----------|---------------------|----------------------|----------------------------|
| Bergamo  | 0.04964 (**)        | 0.0002915 (***)      | < 2.2e-16 (***)            |
| Malpensa | 0.01871 (**)        | 6.686e-05 (***)      | < 2.2e-16 (***)            |


La variabile  $NO_2$  misurata a Bergamo mostra un rifiuto dell'ipotesi nulla di normalità dei dati, ma con un valore molto prossimo alla soglia del 5% che potrebbe generare dubbi: se avessimo, infatti, un livello di significatività più restrittivo (come  $\alpha = 1\%$ ), si accetterebbe l'ipotesi di normalità dei dati. Proprio per ovviare a questa incertezza, è opportuno sfruttare gli altri due test, che confermano quanto già osservato dall'istogramma e dal box-plot, ovvero assenza di normalità dei dati.

La variabile  $NO_2$  misurata a Malpensa mostra i medesimi risultati, ma con un p-value del test di Bera-Jarque più piccolo che, con un livello di significatività del 5%, non lascia alcun dubbio di rifiuto dell'ipotesi nulla. Anche in questo caso, con un  $\alpha = 1\%$  si accetta  $H_0$ . Qualsiasi controversia viene però agevolmente risolta mediante l'impiego degli altri due test: i dati non seguono una distribuzione normale. Conclusione coerente con quanto osservato graficamente.

c) Outlier: non sono presenti in nessuna delle due serie storiche come osservabile dal box-plot.


d) Analisi persistenza e autocorrelazione dei dati


Presa la serie storica di  $NO_2$  di Bergamo, anche dai grafici di ACF emerge la forte stagionalità già discussa in precedenza; infatti, il ritardo 12 è fortemente correlato positivamente con il valore contemporaneo, e stessa cosa del ritardo 24 e 36. Anche se diminuisce, la stagionalità rimane abbastanza persistente perché, dopo 3 anni, è ancora al 40%. I ritardi invece 6, 18 e 30 sono invece inversamente correlati.



Dal correlogramma parziale, invece, eliminati gli effetti intermedi, non risultano significativi i ritardi oltre il quinto; quindi, la correlazione sparisce dopo il quinto mese anche se complessivamente sembra essere fortemente correlato nel brevissimo termine (a un mese) con un valore di quasi 0,8. Quindi la stagionalità è forte, ma solo tenendo conto dei ritardi intermedi, mentre sparisce osservando un correlogramma parziale.

I medesimi commenti si possono fare per i grafici ACF e PACF della serie storica di  $NO_2$  a Milano Malpensa: un piccolo elemento di differenza è notevole nel correlogramma parziale dove il lag 10 sembra essere significativo. In realtà, il valore rimane comunque molto basso, intorno allo 0,25 circa, con bande di confidenza poste a circa  $\pm 0,20$ .





Dai lag-plot, le conclusioni sono le medesime presentate sopra: è evidente per entrambe le serie storiche la forte autocorrelazione soprattutto al ritardo 12, presente anche poi al ritardo 24 e 36 seppur in diminuzione. Così come, la correlazione che si riscontra tra il ritardo 6, 18 e 30, inversa rispetto al lag 1.

Per commentare l'autocorrelazione delle serie, gli ultimi strumenti a nostra disposizione sono analitici e sono le due versioni del test di Portmanteau: i test di Ljung-Box e di Box-Pierce. Il test verifica l'ipotesi congiunta di serie non persistente  $H_0: \rho_1 = \rho_2 = \dots = \rho_k = 0$ , contro l'ipotesi alternativa  $H_1$ : almeno un  $\rho_k \neq 0$ . Il limite di questo test è che, in caso di rifiuto di ipotesi nulla, non mi indica quale sia il coefficiente di autocorrelazione statisticamente significativo. L'accettazione dell'ipotesi nulla implica che la serie sia la realizzazione di un processo White Noise. Per poter svolgere questo test, bisognerebbe scegliere il numero di ritardi  $k$  da testare, ricordando che per le serie stagionali sarebbe ottimo un valore  $k = 2 \cdot m$ , dove  $m$  è la periodicità stagionale. Inoltre, però deve essere rispettata la seguente condizione  $k \leq \frac{n}{5}$ , che con questo dataset significa scegliere un  $k \leq 16$ .

Anche in questo caso, utilizziamo una tabella con solo il valore del p-value.

| <i>Test di Ljung-Box</i> | <i>Bergamo</i> | <i>Malpensa</i> | <i>Test di Box &amp; Pierce</i> | <i>Bergamo</i> | <i>Malpensa</i> |
|--------------------------|----------------|-----------------|---------------------------------|----------------|-----------------|
| $k = 1$                  | 3.79e-13 (***) | 2.12e-13 (***)  | $k = 1$                         | 9.78e-13 (***) | 5.60e-13 (***)  |
| $k = 2$                  | 4.44e-16 (***) | 6.66e-16 (***)  | $k = 2$                         | 1.88e-15 (***) | 2.44e-15 (***)  |
| $k = 3$                  | 2.77e-15 (***) | 4.44e-15 (***)  | $k = 3$                         | 1.05e-14 (***) | 1.64e-14 (***)  |
| $k = 6$                  | 0.0000 (***)   | 0.0000 (***)    | $k = 6$                         | 0.0000 (***)   | 0.0000 (***)    |
| $k = 12$                 | 0.0000 (***)   | 0.0000 (***)    | $k = 12$                        | 0.0000 (***)   | 0.0000 (***)    |

Dai risultati, non ci sono dubbi: fin dal primo ritardo  $k = 1$ , si rifiuta sempre l'ipotesi nulla che la serie sia la realizzazione di un processo White Noise e i dati presentano correlazione, come ci aspettavamo.

#### e) Trasformazione di Box-Cox


Dal momento che le due serie storiche presentano delle asimmetrie, si può utilizzare la trasformata di Box-Cox distinguendo due approcci diversi: il metodo di Guerrero o la log-likelihood.


In riferimento alla serie storica dell' $\text{NO}_2$  a Bergamo, i risultati che si ottengono sono:

- Guerrero:  $\lambda = 0.1317342$
- Log-likelihood:  $\lambda = 0$

I due risultati sono statisticamente uguali, infatti se costruisco quattro diversi modelli di regressione lineare, per tutti e quattro la trasformazione ottima è quella logaritmica: il valore  $\lambda = 0$  ricade sempre nell'intervallo di confidenza.

Da questi modelli di regressioni, è possibile anche osservare come i risultati siano pressoché uguali con o senza trend: questo significa che la serie storica non è caratterizzata da alcun trend, a conferma di quanto già ribadito precedentemente. È presente invece una stagionalità.





Nonostante la trasformazione logaritmica, i dati presentano questa distribuzione, ben lontana dalla normalità, come viene anche confermato dai test di Shapiro-Wilk e Kolmogorov-Smirnov. Il test di Bera-Jarque è l'unico per cui accetterei l'ipotesi nulla di normalità dei dati, ad un livello di significatività  $\alpha = 5\%$ , ma nonostante questo preferiamo non trasformare i dati e non perdere quindi di interpretabilità.

|                                   |                 |
|-----------------------------------|-----------------|
| <b>Test di Bera-Jarque</b>        | 0.07096 (*)     |
| <b>Test di Shapiro-Wilk</b>       | 0.003687 (***)  |
| <b>Test di Kolmogorov-Smirnov</b> | < 2.2e-16 (***) |


Si procede nello stesso modo per la variabile NO<sub>2</sub> a Malpensa. In questo caso, i  $\lambda$  sono:

- Guerrero:  $\lambda = -0.2626928$
- Log-likelihood:  $\lambda = 0.2$

Dai modelli di regressione a lato risultano essere entrambi statisticamente uguali a zero.

Applicando la trasformazione logaritmica, anche in questo caso non si risolve il problema dell'asimmetria, infatti la distribuzione sembra più uniforme. I tre test in realtà danno risultati discordanti, ma preferiamo non applicare alcuna trasformazione ai dati, nonostante possa risolvere in parte l'eteroschedasticità.

|                                   |                 |
|-----------------------------------|-----------------|
| <b>Test di Bera-Jarque</b>        | 0.1139          |
| <b>Test di Shapiro-Wilk</b>       | 0.01482 (**)    |
| <b>Test di Kolmogorov-Smirnov</b> | < 2.2e-16 (***) |



Di seguito, per semplificare, svolgiamo l'analisi prima solo sulla serie **NO<sub>2</sub> a Bergamo**.


#### f) Destagionalizzazione

Prima di effettuare l'analisi della stazionarietà, scegliamo di procedere con una destagionalizzazione: il test di Dickey-Fuller nella versione aumentata (ADF) testa l'ipotesi nulla di non stazionarietà dei dati. In realtà, questa serie presenta una forte stagionalità, quindi si sceglie di rimuovere questa componente e solo successivamente andare a effettuare il test ADF.


Optiamo all'inizio per una regressione armonica, per capire se rimuovendo la stagionalità deterministica, si ottiene un processo stazionario o se ci sono ulteriori componenti deterministiche (come un trend) o componenti stocastiche. Costruiamo sei diversi modelli, ognuno con un numero di armoniche K che va da 1 a 6, dal momento che ho una stagionalità è mensile. Successivamente sfruttiamo i criteri della CV, AIC, AICc, BIC e  $R^2_{adj}$  per scegliere il modello più adatto, ricordando che un numero maggiore di armoniche permette di approssimare meglio l'andamento stagionale, ma scegliendo K troppo elevato genera il rischio di overfitting. Di seguito, presentiamo i risultati:

Dai risultati, il modello più adatto sembrerebbe essere M1, con una sola armonica, perché presenta i valori di CV, AIC, AICc, BIC più bassi, mentre il modello M2 è quello più adatto secondo il criterio  $R^2_{adj}$ . In realtà, anche da una rappresentazione grafica, non sembrano esserci grandi differenze, ma preferiamo optare per il modello 1, secondo un criterio di maggioranza.

| <i>NO<sub>2</sub> Bergamo</i> | <i>CV</i> | <i>AIC</i> | <i>AICc</i> | <i>BIC</i> | <i>R<sup>2</sup><sub>Adj</sub></i> |
|-------------------------------|-----------|------------|-------------|------------|------------------------------------|
| M1                            | 43.25     | 314.5      | 315.02      | 324.18     | 0.77                               |
| M2                            | 43.47     | 314.66     | 315.77      | 329.17     | 0.78                               |
| M3                            | 45.68     | 318.36     | 320.31      | 337.71     | 0.77                               |
| M4                            | 46.94     | 320.05     | 323.11      | 344.24     | 0.77                               |
| M5                            | 48.73     | 322.41     | 326.87      | 351.44     | 0.77                               |
| M6                            | 50.15     | 324.35     | 329.62      | 355.79     | 0.77                               |






Di seguito, la serie destagionalizzata.



Dal grafico emergono due outlier: uno in corrispondenza del 2020, già ampiamente spiegato e uno nel mese di dicembre 2021. Guardando i valori meteorologici, possiamo ricondurre questa anomalia ad un mese di dicembre con poche piogge e temperature più basse rispetto agli anni precedenti, soprattutto 2019 e 2020. Infatti, anche a dicembre 2018, sembra esserci un valore più alto rispetto a queste due annate, dovuto anche qui a una quantità di precipitazioni inferiore.

A livello di analisi, le fluttuazioni stagionali sono state rimosse e, al netto del calo in corrispondenza del biennio 2020-2021 (COVID-19), sembra essere anche stazionaria con media zero. Inoltre, dall'istogramma sembra anche avere una distribuzione abbastanza normale, come anche confermato dal test di Bera-Jarque, con un p-value di 0.739 che mi porta ad accettare l'ipotesi nulla di normalità dei dati.



L'ACF diventa non significativa già al lag 5, ma in realtà ad eccezione del primo lag, i valori sono molto bassi, e soprattutto non ci sono più picchi ai lag 12, 24 o 36, segno che la stagionalità è stata rimossa correttamente. Possiamo, però, svolgere il test ADF per confermare la stazionarietà della serie da un punto di vista analitico ed essere più sicuri.

#### g) Analisi della stazionarietà

Per capire se un processo è stazionario o no, si può impiegare il test di Dickey-Fuller (nella versione aumentata) ADF, che testa l'ipotesi nulla  $H_0: |\phi| = 1$  contro l'ipotesi alternativa  $H_1: |\phi| < 1$ . Accettare l'ipotesi nulla significa che c'è una radice unitaria nel modello autoregressivo AR(1), cioè il processo è un random walk, non stazionario.

Quando si studia la stazionarietà, l'ideale sarebbe partire dal modello più complesso, con trend e costante perché, se si partisse dal modello più semplice (senza intercetta), si rischierebbe di arrivare a conclusioni affrettate e sbagliate, perché si potrebbe scegliere di accettare l'ipotesi di non stazionarietà, solo perché non

si ipotizza la presenza di un trend. Rifiutare l'ipotesi nulla in questo caso significherebbe che la serie è stazionaria attorno a un trend deterministico e quindi sarebbe inutile indagare sugli altri due modelli, dal momento che so già che la serie presenta un trend. In realtà, però, noi abbiamo già rimosso una componente stagionale e dai grafici sopra sembra presentare una stazionarietà, quindi possiamo tranquillamente iniziare dal modello più semplice, perché non ci aspettiamo di accettare l'ipotesi nulla di non stazionarietà. Presentiamo i risultati del modello di regressione solo della statistica test *tau1* per il modello senza intercetta e senza costante ("none"), *tau2* per il modello con costante ("drift"), *tau3* per il modello con trend deterministico ("trend"):

| Modello | Test-statistic | Critical Values | 1%    | 5%    | 10%   |
|---------|----------------|-----------------|-------|-------|-------|
| None    | -3.8491        | <i>tau1</i>     | -2.6  | -1.95 | -1.61 |
| Drift   | -3.8242        | <i>tau2</i>     | -3.51 | -2.89 | -2.58 |
| Trend   | -3.8088        | <i>tau3</i>     | -4.04 | -3.45 | -3.15 |

Dai risultati emerge che sicuramente la serie è stazionaria, infatti rifiuto la presenza di una radice unitaria in tutti e tre i test. L'unico dubbio viene nel modello con il trend deterministico, dove accetto l'ipotesi nulla a un livello di significatività dell'1%. In realtà è un risultato molto borderline, che potrebbe indicare la presenza di un trend deterministico molto debole o delle piccole fluttuazioni, ma non comparabili a una radice unitaria.

Dal grafico della serie destagionalizzata non sembra essere presente un possibile trend, cosa che viene anche poi confermata, andando a svolgere, per completezza, una detrendizzazione. La serie non cambia, e i risultati presentano una variazione stimata di -0.006052, con un p-value di 0.837, assolutamente non significativo. Si sceglie quindi di omettere questa parte.

Un ultimo commento che si può fare riguarda la possibilità di un trend polinomiale: il motivo è che sembrerebbe effettivamente avere un andamento a "S", tipico del trend cubico. Nella realtà, da un'attenta analisi, bisogna notare che in corrispondenza del 2020-2021 c'è stato un cambiamento brusco e improvviso dovuto in realtà a un break strutturale (pandemia di COVID-19), quindi optare per un trend polinomiale porterebbe a conclusioni errate, facendo pensare che quel calo sia tipico di un andamento di lungo periodo. Nella realtà non è così e non si rifletterebbe la realtà del fenomeno, usando uno strumento inadatto per modellarlo.

Svolgiamo gli stessi processi sulla **serie NO<sub>2</sub> di Malpensa**.


#### f) Destagionalizzazione

Anche in questo caso, data la forte stagionalità, si sceglie di procedere subito rimuovendola. Sfruttiamo la regressione armonica, e scegliamo il modello migliore tra i sei possibili ( $K_{\max} = 6$ ). I risultati sono a lato: tutti i criteri concordano sul modello M2, con due armoniche, come il migliore.

| NO <sub>2</sub> Malpensa | CV    | AIC    | AICc   | BIC    | R <sup>2</sup> <sub>Adj</sub> |
|--------------------------|-------|--------|--------|--------|-------------------------------|
| M1                       | 32.73 | 291.36 | 291.87 | 301.03 | 0.78                          |
| M2                       | 28.17 | 278.62 | 279.73 | 293.13 | 0.82                          |
| M3                       | 29.47 | 281.94 | 283.88 | 301.29 | 0.81                          |
| M4                       | 30.80 | 285.05 | 288.11 | 309.24 | 0.81                          |
| M5                       | 32.21 | 288.07 | 292.52 | 317.09 | 0.81                          |
| M6                       | 33.13 | 289.97 | 295.24 | 321.41 | 0.81                          |

La componente stagionale è stata rimossa, infatti

non ci sono più fluttuazioni a frequenza costante. A differenza, però della serie dell'NO<sub>2</sub> a Bergamo, sembra anche essere presente una componente di trend di lungo periodo, infatti c'è un andamento decrescente. Per essere, però, sicuri che sia una componente deterministica ha senso procedere subito con il test ADF, in modo tale da capire se la detrendizzazione sia la scelta corretta o se la componente è stocastica e quindi necessita di una differenziazione.



#### g) Analisi della stazionarietà


Svolgiamo il test di Dickey-Fuller aumentato, innanzitutto nella sua versione più complessa dal momento che dal grafico sembra essere presente un trend deterministico. Di seguito i risultati:

| Modello | Test-statistic | Critical Values   | 1%    | 5%    | 10%   |
|---------|----------------|-------------------|-------|-------|-------|
| None    | -3.5571        | $\tau_{\alpha 1}$ | -2.6  | -1.95 | -1.61 |
| Drift   | -3.5311        | $\tau_{\alpha 2}$ | -3.51 | -2.89 | -2.58 |
| Trend   | -5.163         | $\tau_{\alpha 3}$ | -4.04 | -3.45 | -3.15 |

Si rifiuta sempre l'ipotesi nulla di dati generati da un modello AR(p) con radice unitaria. Quindi, è logico pensare che ci sia un trend deterministico attorno a cui la serie si muove.

#### h) Detrendizzazione



Abbiamo optato per un trend lineare deterministico, perché sembra esserci un andamento decrescente, infatti, così come per la serie relativa alla città di Bergamo, non bisogna farsi ingannare dalla presenza del break strutturale presente nel biennio 2020-2021. La serie aveva già un andamento di lungo periodo che presentava una decrescita e questo era già evidente dal grafico della serie storica originale, dove i picchi positivi erano in continua decrescita.



Un aspetto notevole è il picco elevato (probabilmente outlier) in corrispondenza del gennaio 2017: quell'anno, nell'arco temporale preso in considerazione, ha visto il livello di temperatura più basso, addirittura sotto 0°C, oltre che valori bassissimi di piogge cumulate. Questo potrebbe aver generato un aumento del riscaldamento domestico e, di conseguenza, valori più elevati di inquinante.

In termini di analisi, ora la serie sembra stazionaria con media zero. Ha una distribuzione normale e come sospettavamo, sono presenti due outlier, già discussi precedentemente. Il test di Bera-Jarque mi restituisce un p-value di 0.2546, che mi porta ad accettare l'ipotesi nulla di distribuzione normale.

Abbiamo provato a optare anche per una detrendizzazione polinomiale: mettendo a confronto vari modelli, dai criteri di cross-validation il migliore sembrava il trend di ordine terzo. Nella realtà però, osservando la serie detrendizzata in questo modo, si è deciso di non proseguire così: il motivo è che si rischia di spiegare il break strutturale con un trend, come se fosse una transizione graduale e tipica, ma nella realtà non è così.



Un ultimo commento lo si può fare guardando i correlogrammi e i correlogrammi parziali, che non possono che confermare la rimozione corretta delle componenti deterministiche stagionali e trend, infatti ad eccezione del lag 1, tutti gli altri sono non significativi.

La destagionalizzazione con la regressione armonica e la detrendizzazione lineare hanno reso la serie stazionaria attorno allo zero.

## 2.2. Variabile PM<sub>10</sub> (misurata in $\mu\text{g}/\text{m}^3$ )



### a) Grafico

Le serie storiche che descrivono il comportamento dell'inquinante PM<sub>10</sub> hanno un comportamento molto simile, anche in termini di picchi positivi e negativi. Entrambe le serie storiche presentano un'importante dipendenza stagionale: come altri inquinanti, il PM<sub>10</sub> mostra valori elevati in corrispondenza del periodo invernale e valori più bassi in corrispondenza dei mesi più caldi. I motivi sono riconducibili al fatto che con le basse temperature, c'è una peggiore capacità dispersiva dell'atmosfera perché le inversioni termiche intrappolano l'aria fredda e gli inquinanti vicino al suolo (come già descritto per l'NO<sub>2</sub>); inoltre c'è una maggiore presenza di sorgenti aggiuntive, come il riscaldamento domestico, che portano a livelli più elevati di inquinamento durante l'inverno. Al di là, invece, dell'aspetto meteorologico, si possono raggiungere valori più elevati a causa di incendi o traffico elevato. La concentrazione di PM<sub>10</sub>, invece, diminuisce con la pioggia, perché l'acqua cattura le particelle sospese nell'aria e le trasporta al suolo. Infatti, i tipici temporali estivi sono un buon alleato nella lotta contro l'inquinamento da PM<sub>10</sub>. Livelli più bassi di PM<sub>10</sub> possono essere raggiunti grazie alla dispersione verticale estiva (con alte temperature e intensa radiazione solare), oltre che alla presenza di venti forti che riducono le concentrazioni locali diluendo e disperdendo gli inquinanti.

Focalizzandoci sul confronto tra le due stazioni, si può dire che, a differenza dell'NO<sub>2</sub>, dove vi erano alcune differenze, nel caso del particolato i livelli di inquinamento sono molto simili, infatti le due serie sembrano essere quasi sovrapposte. Principali differenze si notano a partire da circa marzo 2021, dove i valori di Malpensa sono sempre stati più elevati rispetto a Bergamo. Ciò fa pensare che ci siano fattori comuni nelle due aree, come le temperature e più in generale il clima, che influenzano nello stesso modo il particolato.

A differenza dell'NO<sub>2</sub> che mostrava evidenti anomalie in corrispondenza del biennio 2020-2021, legate quindi al COVID-19, per il PM<sub>10</sub> non si notano invece break strutturali in quello stesso periodo: questo risultato potrebbe essere dovuto dal fatto che il PM<sub>10</sub> a differenza dell'NO<sub>2</sub> viene influenzato meno dall'impatto veicolare, e quindi ha risentito in misura inferiore delle restrizioni imposte a seguito della pandemia da COVID-19. In realtà, sembrano esserci solo valori insolitamente alti nell'inverno del 2017: nel mese di dicembre 2016 infatti a Bergamo le piogge presentano addirittura un valori pari a 0 mm e 2.8mm a gennaio 2017, con una temperatura di 1,5°C, ben sotto dai valori nello stesso periodo degli altri anni. Lo stesso commento lo si può fare in riferimento alla centralina di Ferno, dove a dicembre 2016 i millimetri di pioggia erano 3.4, e 2.4 a gennaio 2017, con anche temperature sottozero, e anche in questo caso, valori ben diversi da quelli riscontrati negli altri anni.

Anche in questo caso, nonostante l'arco temporale di soli sette anni, sovrapponiamo alle serie storiche una funzione a gradini che rappresenta la media (calcolata annualmente) per osservare la presenza di un eventuale trend: per quel che riguarda la serie di Bergamo, sembra esserci un trend decrescente. Ad eccezione di valori molto elevati nel 2017, il particolato diminuisce nel tempo. In particolare, dal 2021 al 2022 ha subito un leggero incremento ma quasi impercettibile. In corrispondenza di Malpensa, invece, la media sembra essere abbastanza stabile: dopo una salita nel 2017 e




conseguente discesa nel biennio successivo, i valori dal 2020 in poi sono tornati ad essere molto simili a quelli del 2016.

Ad eccezione del 2017, in entrambe le serie sembra esserci una stazionarietà in varianza, perché con il passare del tempo, l'ampiezza delle oscillazioni non aumenta/diminuisce in modo continuo. Sicuramente sono serie non stazionarie a causa della forte componente stagionale; quindi, è necessario intervenire destagionalizzando come primo passo. Inoltre, la serie di Bergamo sembra essere caratterizzata da un trend di lungo periodo decrescente, come evidenziato dalle medie annuali. Sono però serie persistenti: non ci sono continue oscillazioni verso l'alto e verso il basso.

Dai grafici, quindi, concludiamo che l'inquinante  $PM_{10}$  ha un forte andamento stagionale, dovuto al clima, ma non ci sono importanti discostamenti presso le due centraline. In generale, però, i valori del particolato presso ambedue le centraline sono sempre stati inferiori alla soglia di allarme di  $40\mu g/m^3$  annuali, ma purtroppo ancora troppo elevati rispetto ai livelli raccomandati dall'OMS che sono pari a  $15\mu g/m^3$  annuale.

## b) Distribuzione dei dati



Commentiamo in contemporanea i risultati delle due centraline, perché il comportamento dei dati sembra essere quasi identico: in realtà, avevamo appunto già notato dalle serie storiche sovrapposte, andamenti quasi simili. Da entrambi gli istogramma sembra che la variabile  $PM_{10}$  sia asimmetrica positiva, con una coda a destra, come viene confermato anche dal box-plot, che presenta un baffo destro più lungo rispetto a quello sinistro. C'è una maggiore concentrazione di valori del  $PM_{10}$  intorno al  $20\mu g/m^3$ , infatti la mediana è circa  $24\mu g/m^3$ . Questo era atteso, perché come già sottolineato il particolato rimane sotto la soglia d'allarme, ma purtroppo ben oltre i valori raccomandati. Inoltre, i box-plot non evidenziano per nessuna delle due serie storiche possibili outlier. Questi risultati di assenza di normalità possono essere confermati dai test analitici, con ipotesi nulla  $H_0$ : dati distribuiti normalmente.

| $PM_{10}$ | Test di Bera-Jarque | Test di Shapiro-Wilk | Test di Kolmogorov-Smirnov |
|-----------|---------------------|----------------------|----------------------------|
| Bergamo   | 0.01975 (**)        | 5.978e-05 (***)      | < 2.2e-16 (***)            |
| Malpensa  | 0.00879 (***)       | 5.333e-06 (***)      | < 2.2e-16 (***)            |

I risultati precedenti trovano conferma nei p-value ottenuti dai tre test. Se, però, per la variabile  $PM_{10}$  relativa alla centralina di Milano Malpensa non ci sono dubbi, l'unico piccolo dubbio potrebbe riguardare la centralina di Bergamo, perché con il test di Bera-Jarque, si accetta l'ipotesi nulla di normalità dei dati per un valore  $\alpha = 1\%$ . Nonostante ciò, concludiamo che i dati non sono normali, proprio perché per la maggior parte dei test si rigetta l'ipotesi nulla, oltre a un'osservazione del grafico. Tra tutti i test svolti, però, sottolineiamo che il test di Bera-Jarque è l'unico dove i valori del p-value, sebbene inferiori alle soglie, non hanno mai raggiunto valori molto prossimi allo 0 (cioè, inferiori a ordini di  $10^{-5}$  o addirittura inferiori a ordini di  $10^{-16}$ ).



c) Outlier: non sono presenti in nessuna delle due serie storiche come osservabile dal box-plot.

d) Analisi persistenza e autocorrelazione dei dati

Anche per i correlogramma e correlogramma parziale, possiamo fare un unico commento, dato che il comportamento dell'inquinante è pressoché identico presso le due centraline: dal grafico dell'ACF si riconferma la forte stagionalità già discussa in precedenza: il ritardo 12 è fortemente correlato con il valore dello stesso mese dell'anno precedente, e stessa cosa si può dire del lag 24 e 36. È, quindi, come ci aspettavamo una serie persistente: dopo 3 anni è ancora al 40%. Anche i ritardi 6, 18, e 30 sono molto correlati, ma inversamente.

Dal correlogramma parziale, invece, eliminati gli effetti intermedi, sembrano essere significativi solo i lag 3, 4, 5, ma la correlazione risulta essere molto bassa.

Dal PACF, invece, eliminati gli effetti intermedi emerge che solo le serie sono fortemente correlate nel brevissimo termine (a un mese). La stagionalità, quindi, è forte, ma solo tenendo conto dei ritardi intermedi, infatti sparisce osservando un correlogramma parziale.



I risultati precedenti trovano conferma nei lag-plot: è evidente la forte autocorrelazione ai ritardi 12, 24 e 36, segno di forte stagionalità (infatti, le rette sono molto vicine alla bisettrice). Al contrario, con il lag 6, 18 e 30 c'è una correlazione inversa rispetto al lag 1.

Altri strumenti di supporto per studiare l'autocorrelazione sono i test di Portmanteau nelle due versioni di Ljung-Box e di Box-Pierce. Nella tabella seguente, i risultati:

| <i>Test di Ljung-Box</i> | <i>Bergamo</i> | <i>Malpensa</i> | <i>Test di Box &amp; Pierce</i> | <i>Bergamo</i> | <i>Malpensa</i> |
|--------------------------|----------------|-----------------|---------------------------------|----------------|-----------------|
| $k = 1$                  | 2.45e-09 (***) | 1.02e-09 (***)  | $k = 1$                         | 4.67e-09 (***) | 2.01e-09 (***)  |
| $k = 2$                  | 7.84e-11 (***) | 1.04e-10 (***)  | $k = 2$                         | 1.90e-10 (***) | 2.46e-10 (***)  |
| $k = 3$                  | 3.97e-10 (***) | 5.70e-10 (***)  | $k = 3$                         | 9.51e-10 (***) | 1.32e-09 (***)  |
| $k = 6$                  | 0.0000 (***)   | 0.0000 (***)    | $k = 6$                         | 0.0000 (***)   | 0.0000 (***)    |
| $k = 12$                 | 0.0000 (***)   | 0.0000 (***)    | $k = 12$                        | 0.0000 (***)   | 0.0000 (***)    |



I risultati sono molto chiari: in ogni possibile caso, si rifiuta l'ipotesi nulla che la serie sia la realizzazione di un processo White Noise, quindi i dati presentano una forte autocorrelazione. Il risultato è in linea con i commenti precedenti. Le serie sono persistenti.

### e) Trasformazione di Box-Cox

Le due serie storiche non sono normali, come osservato precedentemente, quindi possiamo sfruttare la trasformazione di Box-Cox per cercare di renderle simmetriche.

I valori di  $\lambda$  relativi alla serie storica del PM<sub>10</sub> di Bergamo sono:

- Guerrero:  $\lambda = -0.1318654$
- Log-likelihood:  $\lambda = -0.15$




I due valori sono statisticamente uguali e sono uguali a zero: la trasformazione logaritmica risulta essere ottima per tutti e quattro di modelli di regressione che posso costruire.

In realtà, però, nonostante la trasformazione logaritmica, i dati si discostano ancora dalla normalità, anzi sembrano avere un andamento bimodale. I tre test presentano però risultati molto discordanti: il test di Bera-Jarque accetta l'ipotesi nulla, quindi considera i dati normali; il test di Shapiro-Wilk rifiuta l'ipotesi nulla per un livello di significatività  $\alpha = 5\%$ ; il test di Kolmogorov-Smirnov rifiuta all'1%.

**Test di Bera-Jarque**  
**Test di Shapiro-Wilk**  
**Test di Kolmogorov-Smirnov**

0.1365  
0.02134 (\*\*)  
< 2.2e-16 (\*\*\*)

Scegliamo però di proseguire con la trasformazione logaritmica. La serie ha ora questa rappresentazione, da cui sembra essere presente, come già avevamo sospettato prima un trend decrescente.





Svolgendo la stessa analisi per la variabile PM<sub>10</sub> relativa alla centralina di Malpensa. In questo caso, i valori di  $\lambda$  sono:

- Guerrero:  $\lambda = -0.5700564$
- Log-likelihood:  $\lambda = -0.35$

Non sono uguali e soprattutto il  $\lambda$  di Guerrero potrebbe anche far pensare per una trasformazione inversa, quindi verifichiamo se rientrano o meno nello stesso intervallo di confidenza.

Da questi grafici, possiamo concludere che rientrano sempre negli stessi intervalli di confidenza e che la trasformazione inversa non è un'opzione, dal momento che il valore di -1 è sempre fuori. Scegliamo, anche in questo caso la trasformazione logaritmica.



**Test di Bera-Jarque**  
**Test di Shapiro-Wilk**  
**Test di Kolmogorov-Smirnov**

0.0595 (\*)  
0.001564 (\*\*\*)  
< 2.2e-16 (\*\*\*)

I risultati dell'istogramma non fanno pensare, però, neanche in questo caso ad una trasformazione logaritmica, perché la distribuzione sembra sempre bimodale, e soprattutto con una leggera asimmetria. Infatti, si rifiuta l'ipotesi nulla di normalità dei dati in modo estremamente significativo per due test su tre. Si prosegue, quindi, con la variabile originaria.

Focalizziamoci innanzitutto sulla serie del **PM<sub>10</sub> a Bergamo**.


#### f) Destagionalizzazione

Prima di svolgere l'analisi della stazionarietà, così come per la variabile NO<sub>2</sub>, si sceglie di destagionalizzare, dato che è una componente sicuramente presente. Quindi, solo dopo aver rimosso la stagionalità, vado a studiare la serie per capire se la media è diventata costante o se c'è ancora una componente di non stazionarietà, come un trend. Si opta per una regressione armonica come punto di partenza per capire se eliminando la stagionalità si ottiene un processo stazionario. A lato, i risultati in termini di criteri di adattamento per capire il numero ottimale di armoniche da considerare.

Il modello più adatto sembrerebbe essere M4, con quattro armoniche.

Proseguiamo, destagionalizzando la serie.

| PM <sub>10</sub> Bergamo | CV   | AIC     | AICc    | BIC     | R <sup>2</sup> <sub>Adj</sub> |
|--------------------------|------|---------|---------|---------|-------------------------------|
| M1                       | 0.06 | -231.1  | -230.58 | -221.42 | 0.70                          |
| M2                       | 0.06 | -228.9  | -227.79 | -214.39 | 0.70                          |
| M3                       | 0.06 | -230.86 | -228.92 | -211.51 | 0.72                          |
| M4                       | 0.06 | -235.45 | -232.4  | -211.26 | 0.74                          |
| M5                       | 0.06 | -231.64 | -227.18 | -202.61 | 0.73                          |
| M6                       | 0.06 | -230.71 | -225.44 | -199.27 | 0.73                          |






Dal grafico, sembrano essere presenti due valori anomali: uno in corrispondenza di ottobre 2017 (variazione di 0.6) e uno in corrispondenza di novembre 2019 (valore di quasi -0.6). Infatti, in realtà dai dati originali è proprio in quei due mesi che si riscontrano valori insolitamente diversi da quelli dai mesi vicini. Le motivazioni possono essere riconducibili alla meteorologia: ottobre 2017 è stato un mese caratterizzato da assenza di pioggia, mentre il mese di novembre 2019 aveva raggiunto un accumulo di pioggia di 232,4 mm, molto alto rispetto ai mesi precedenti e seguenti.

Come già sospettavamo dalla serie storica originale, il COVID non sembra invece aver impattato particolarmente sul livello del PM<sub>10</sub>, anche al netto della stagionalità, a differenza dell'NO<sub>2</sub> dove erano evidenti dei break strutturali.

Osservando l'istogramma della serie destagionalizzata, possiamo affermare che sicuramente è stata rimossa l'asimmetria e sembra avere un andamento più normale della serie storica originale, tanto che la densità kernel quasi si sovrappone alla curva teorica normale. Questo viene confermato anche dai test analitici, per cui accetto l'ipotesi nulla con un p-value di 0.7884.

In realtà, questi risultati sono stati ottenuti solo provvedendo all'applicazione della trasformazione di Box-Cox. Senza questa, la serie risultava ancora fortemente anormale.

Istogramma della concentrazione di log(PM10) destagionalizzata Bergamo Città



I risultati presentati dalla ACF e PACF sono molto buoni: l'autocorrelazione è completamente non significativa a qualsiasi ritardo. Si può notare solo un valore fuori dalle bande di confidenza al lag 7, ma

rimane comunque un valore molto contenuto, dato che supera appena lo 0.3. Svolgiamo il test ADF per confermare la stazionarietà.

#### g) Analisi della stazionarietà


Studiamo la stazionarietà, per capire se è stazionaria, o se è presente ancora qualche componente deterministica, come ad esempio un trend come sospettiamo e come, anche se in maniera meno evidente, continua a sembrare dal grafico della serie destagionalizzata. Il test ADF mi restituisce i seguenti risultati:

| Modello | Test-statistic | Critical Values | 1%    | 5%    | 10%   |
|---------|----------------|-----------------|-------|-------|-------|
| None    | -0.6138        | $\tau_1$        | -2.6  | -1.95 | -1.61 |
| Drift   | -4.1541        | $\tau_2$        | -3.51 | -2.89 | -2.58 |
| Trend   | -4.2903        | $\tau_3$        | -4.04 | -3.45 | -3.15 |


Sicuramente la serie non presenta una radice unitaria, altrimenti avrei accettato l'ipotesi nulla anche in corrispondenza dei test con l'opzione "drift" e "trend".

#### h) Detrendizzazione

Dal grafico sembra evidente un trend lineare deterministico decrescente. I risultati sembrano molto buoni dai grafici che seguono: ovviamente nella scelta della tipologia di detrendizzazione, bisogna ricordare di non farsi trarre in inganno dai valori anomali riscontrati di cui abbiamo già discusso precedentemente.




L'istogramma seguente evidenzia la distribuzione dei dati e il p-value ora è di 0.5678: dal grafico sembra essere ancora normale, anche se rispetto alla singola destagionalizzazione sembra essere diventata leggermente asimmetrica. Tuttavia, il p-value mi porta comunque ad accettare l'ipotesi nulla di normalità. Inoltre, dai grafici di ACF e PACF risulta essere anche sparita l'autocorrelazione presente nei dati, con i test ADF che confermano in modo robusto la stazionarietà della serie destagionalizzata e detrendizzata.



Dal correlogramma e dal correlogramma parziale, l'unico lag significativo è il dodicesimo. Questo potrebbe far pensare a un termine di media mobile stagionale e un termine autoregressivo stagionale.

Per curiosità, abbiamo provato a modellare anche la serie storica sfruttando un trend polinomiale: dai risultati, il modello migliore sembrava il polinomio di grado quarto. In realtà, sembra essere un ottimo strumento rispetto al semplice trend per modellare quello che accade all'inizio della serie storica (nel 2016), dove ci sono valori più bassi che successivamente salgono (ricordiamo che usando i logaritmi, si parla sempre di variazioni), ma in realtà accade poi che verso la fine del 2020 mi segna una variazione improvvisa

molto elevata, anche rispetto a quella già riscontrata verso la fine del 2017. Quindi, scegliamo comunque di usare la serie storica detrendizzata con un semplice trend lineare.



Proseguiamo adesso con la serie del **PM<sub>10</sub> a Malpensa**.


#### f) Destagionalizzazione

Anche in questo caso, come per gli altri, si procede subito destagionalizzando, essendo molto evidente la componente stagionale. Anche in questo caso, si procede con una regressione armonica. I risultati dei criteri di adattamento sono presentati a lato.

Non ci sono dubbi sul fatto che il modello migliore sia quello con due armoniche, M2.

Procediamo con la destagionalizzazione.

| <i>PM<sub>10</sub> Malpensa</i> | <i>CV</i> | <i>AIC</i> | <i>AICc</i> | <i>BIC</i> | <i>R<sup>2</sup><sub>Adj</sub></i> |
|---------------------------------|-----------|------------|-------------|------------|------------------------------------|
| <i>M1</i>                       | 46.78     | 321.01     | 321.52      | 330.68     | 0.72                               |
| <i>M2</i>                       | 39.72     | 307.16     | 308.27      | 321.67     | 0.77                               |
| <i>M3</i>                       | 40.67     | 308.78     | 310.72      | 328.13     | 0.77                               |
| <i>M4</i>                       | 41.59     | 310.17     | 313.22      | 334.36     | 0.77                               |
| <i>M5</i>                       | 43.62     | 313.56     | 318.02      | 342.59     | 0.76                               |
| <i>M6</i>                       | 44.77     | 315.35     | 320.63      | 346.8      | 0.76                               |




La serie non presenta più stagionalità, ma emergono tre valori particolarmente diversi dagli altri:

- Ottobre 2017 e novembre del 2020, in cui le particelle hanno raggiunto valori molto alti: in ambedue le occasioni la quantità di pioggia era veramente molto bassa, addirittura nulla in corrispondenza di ottobre 2017, e di solo 6,4 mm nel mese di novembre 2020, contro un mese di ottobre 2020


caratterizzato da abbondanti precipitazioni (225,6 mm) che sicuramente hanno permesso una diminuzione dei livelli del particolato.

- Novembre 2019, con valori molto bassi: dalla serie storica originale in realtà, con stagionalità, questo valore non risultava molto differente dagli altri; infatti, da marzo a novembre dello stesso anno i valori oscillavano tra  $12\mu\text{g}/\text{m}^3$  e  $25\mu\text{g}/\text{m}^3$ , ma rimuovendo la componente stagionale, il picco negativo di novembre 2019 sembra essere notevole. Anche in questo caso, il collegamento più immediato è con fattori meteorologici: se nei mesi precedenti, ci si aspettava valori bassi del particolato, con le temperature tipiche di novembre i valori sarebbero dovuti crescere, ma un'elevata quantità di pioggia (239,8 mm) ha sicuramente ridotto i valori del PM<sub>10</sub> rispetto a quelli tipici che si sarebbero dovuti osservare.

Osserviamo la distribuzione della serie destagionalizzata: dal box-plot emergono subito dei valori anomali, che scegliamo quindi di rimuovere con la funzione R *tsclean()*. I valori anomali sono valori che si trovano insolitamente al di fuori della soglia data da  $(x_{0,25} - 1,5 \times IQR; x_{0,75} + 1,5 \times IQR)$ . Ripresentiamo, quindi, di seguito la serie destagionalizzata con gli outlier rimossi.



Dall'istogramma la distribuzione della serie sembra essere ampiamente approssimabile con una normale, e troviamo conferma anche dal test di Bera-Jarque, per cui si accetta l'ipotesi nulla con un p-value di 0.2271.



Sia l'ACF che la PACF dimostrano un'assenza di autocorrelazione tra i dati, dal momento che tutti i lag, ad eccezione del primo, sono non significativi, e inoltre il primo supera le bande di confidenza per un valore irrisorio. Si potrebbe quindi pensare ad un modello AR(1) per la fase di modellistica.

La serie, al netto di alcuni valori anomali (di cui alcuni sono stati rimossi con il filtro di Hampel) sembra essere stazionaria in media e non sembra presentare alcun trend. Si procede, comunque con un'analisi di stazionarietà per avere ulteriori conferme.

#### g) Analisi della stazionarietà

Svolgiamo il test di ADF per completezza. I risultati sono i seguenti:

| Modello | Test-statistic | Critical Values | 1%    | 5%    | 10%   |
|---------|----------------|-----------------|-------|-------|-------|
| None    | -5.2239        | $\tau_1$        | -2.6  | -1.95 | -1.61 |
| Drift   | -5.2355        | $\tau_2$        | -3.51 | -2.89 | -2.58 |
| Trend   | -5.2137        | $\tau_3$        | -4.04 | -3.45 | -3.15 |

In realtà, anche graficamente non sembra essere presente nessuna tipologia di trend.

Procedere con una detrendizzazione sarebbe fuorviante dal momento che la serie è già stazionaria, con media zero, e inoltre, questo rischierebbe di andare a dover necessariamente attribuire un andamento alla serie che in realtà potrebbe essere caratterizzato anche da break strutturali. Abbiamo, infatti, provato a detrendizzare, ma in realtà i risultati presentano una variazione stimata di -0.006283, con un p-value di 0.796, assolutamente non significativo. Omettiamo, quindi, questo ulteriore passaggio.

Riportiamo quindi una conclusione delle analisi svolte:


- Serie NO<sub>2</sub> a Bergamo: i residui seguono un andamento normale, ma c'è un residuo di autocorrelazione come evidente dal grafico dell'ACF, quindi si potrà optare per un AR (1) come sembra dal correlogramma parziale, o anche con un modello ARMA più complesso.
- Serie NO<sub>2</sub> a Malpensa: i residui sono normali e il residuo di autocorrelazione è ancora meno evidente; infatti, solo il lag 1 è significativo. Segno di un possibile AR (1).
- Serie PM<sub>10</sub> a Bergamo: residui normali e ACF/PACF caratterizzata da significatività solo per il lag 12.
- Serie PM<sub>10</sub> a Malpensa: residui normali, ma debole autocorrelazione al ritardo 1, che potrebbe essere modellata con un AR (1).

### 3. Decomposizione delle serie storiche

Avendo dati prettamente stagionali, la fase della decomposizione è molto importante. Esistono varie tecniche di decomposizione, sicuramente quella più nota è la decomposizione classica: il problema principale però di questa tecnica è che sfrutta le medie mobili e di conseguenza comporta la perdita di una parte di osservazioni, in particolare un numero pari a  $\frac{s}{2}$  valori, dove  $s$  indica la periodicità stagionale. Nel nostro caso, con dati con periodicità mensile, si perderebbero ben dodici osservazioni (sei all'inizio e sei

alla fine). Di per sé, non è un numero molto elevato, ma il nostro dataset contiene solo 83 osservazioni complessive, che coprono quasi sette anni, quindi significherebbe perdere circa il 15% delle osservazioni. Proprio per questa motivazione, scegliamo di optare per una decomposizione con metodi alternativi, chiamate decomposizioni ufficiali perché sviluppate da agenzie ufficiali di statistica, come ISTAT ed EUROSTAT. Tra questi metodi, individuiamo la decomposizione con metodo X-11, decomposizione SEATS e decomposizione STL. Li proviamo tutti sulle quattro differenti serie storiche e andiamo a scegliere il metodo migliore di decomposizione.

Partiamo dalla serie storica relativa **all'inquinante NO<sub>2</sub> nella città di Bergamo**. Di seguito presentiamo le quattro differenti decomposizioni e la destagionalizzazione con i vari metodi di decomposizione.




Per la decomposizione X-11 e SEATS è stato usato un modello moltiplicativo, infatti i valori della stagionalità oscillano intorno a uno, mentre nel caso della decomposizione STL oscillano intorno a zero (e questo vale per tutte e quattro le serie storiche). Il trend è molto più ruvido della decomposizione SEATS a confronto con le altre due, ma presenta un problema: in ognuna delle tre decomposizioni il break strutturale del 2020 dovuto al COVID viene catturato dal trend, come se fosse una variazione vera e propria dell'andamento di lungo periodo della serie. La stagionalità, invece, è regolare e stabile nel tempo, oltre che essere molto forte, come sospettavamo dall'inizio. I residui, in ultimo, sembrano avere un andamento casuale attorno allo zero e sembrano distribuirsi come dei White Noise: nella decomposizione STL, però, sono proprio i residui a catturare l'anomalia del 2020 (infatti si notano barre negative, assenti nelle altre due decomposizioni), proprio perché a differenza degli altri due metodi, non viene "catturato" dal trend. Commenti conclusivi possono essere fatti guardando il grafico della destagionalizzazione con i vari metodi di decomposizione: come sospettavamo, i metodi X-11 e SEATS sono molto simili, quasi sovrapposti; il metodo STL, invece, presenta delle differenze, è molto più ruvido e la serie destagionalizzata presenta un calo molto più acuto rispetto alle altre due. Proprio per il comportamento dei residui, probabilmente si sceglie il metodo SEATS o in alternativa il metodo STL: anche osservando l'istogramma dei residui e il test di Bera-Jarque non ci sono dubbi sulla normalità dei residui (accetto ipotesi nulla con un p-value del 95-99%).


In riferimento **all'inquinante NO<sub>2</sub> nei pressi di Milano Malpensa**, invece, possiamo dire che la stagionalità innanzitutto è regolare e molto forte, come già preannunciato. A differenza, però, dell'inquinante NO<sub>2</sub> a Bergamo, questa serie presenta un trend decrescente, che viene infatti catturato da tutte e tre le decomposizioni: la STL, però, come prima lo ingloba quasi completamente, mentre nelle altre due è già più evidente una discesa meno lineare, soprattutto nell'X11). Probabilmente, può essere dovuto a una ripresa molto più lenta del traffico aeroportuale nel corso del tempo, in seguito alla pandemia da COVID-19.

Ricordiamo, inoltre, che la centralina di Bergamo è posta in una zona del centro città, quindi risente del traffico veicolare urbano: la diminuzione delle restrizioni è avvenuta dopo pochi mesi, quindi questo può aver contribuito a un ritorno dell'inquinamento a livelli pre-pandemia molto più rapidamente, rispetto a Malpensa. Inoltre, sicuramente rispetto a prima, in tutti e tre i metodi di decomposizione il trend sembra essere molto più liscio (nel caso precedente, il metodo SEATS sembrava essere molto ruvido rispetto alle altre due decomposizioni).

Anche in questo caso, però, l'evento anomalo del 2020 sembra essere stato catturato interamente dal trend, con un calo abbastanza brusco, anche se in realtà, i livelli di inquinamento sono in costante decrescita dal 2017 ad oggi come mostrato dalla serie originale. Infatti, dal grafico finale è possibile notare due differenti blocchi: uno dal 2016 al 2019, e l'altro dal 2019 ad oggi, quindi incompatibile con l'evento COVID-19. La decomposizione SEATS sembra essere però la migliore, perché cattura il trend decrescente a partire dal 2018, mentre con quella STL c'è un calo continuo fin dal 2016 (il picco della serie originale nel 2017 è maggiore rispetto a quello nel 2016). Escludiamo la X-11, anche dal confronto diretto, perché sembra mostrare un calo soprattutto nella seconda metà del 2019, quando in realtà, il livello di inquinamento sta subendo una decrescita costante. Guardando l'istogramma dei residui e il test di Bera-Jarque, proponiamo la decomposizione SEATS.




**L'inquinante PM<sub>10</sub> a Bergamo**, ricordiamo trasformato in logaritmo tramite Box-Cox, può essere decomposto come segue:



Anche in questo caso, tutte e tre le decomposizioni evidenziano una forte componente stagionale con andamento regolare e una componente residua con fluttuazioni casuali. Tutte e tre le decomposizioni inoltre evidenziano un trend: quella SEATS però a differenza delle altre due evidenzia un trend lineare, la X-11 un trend più ruvido, mentre quella STL non lineare ma più liscio sicuramente. In particolare, nell'X-11 e STL viene evidenziato anche un calo importante a partire dal 2018 in avanti, ed evidenziano una leggera ripresa a partire dalla seconda metà del 2021 (cosa che la decomposizione SEATS non coglie e considera una diminuzione dei livelli più a lungo termine). Tutte e tre le decomposizioni, però, restituiscono serie destagionalizzate quasi sovrapposte, ma considerando il comportamento del trend, si potrebbe escludere sicuramente la decomposizione SEATS, e optare invece per la X-11 che a differenza della STL riesce a cogliere meglio alcuni doppi picchi e un andamento più ruvido della serie storica. Guardando però gli istogrammi e i valori del p-value, la decomposizione che restituisce i residui più normali è proprio la decomposizione SEATS. In realtà, ricordiamo, che nella fase di detrendizzazione svolta precedentemente, noi avevamo optato proprio per un trend lineare

In ultimo, ecco le decomposizioni relative al **PM<sub>10</sub> nei pressi di Milano Malpensa**.



Come per le altre tre serie storiche, anche qua la stagionalità è regolare e molto evidente e viene estratta da tutti e tre i metodi di decomposizione. Anche la componente residua sembra avere un andamento casuale, segno di una buona decomposizione. In questo caso, a differenza delle altre serie storiche, il trend viene estratto in modo simile in tutte e tre le casistiche, anche se ovviamente per la decomposizione X-11 sembra esserci un andamento più liscio. A differenza dell'inquinante NO<sub>2</sub>, il COVID non ha generato break strutturali, infatti in realtà il trend mostra una decrescita dal 2017 (a gennaio 2017 c'erano stati valori particolarmente alti come ben ricordiamo) per poi tornare a valori più contenuti, ma mai uguali a quelli del 2017, e inoltre dalla serie destagionalizzate non c'è alcun calo anomalo in quell'anno.


In generale, tutti e tre i metodi sembrano avere un comportamento simile, soprattutto STL e SEATS, anche se STL sembra cogliere meglio i picchi e soprattutto il trend, in corrispondenza del 2022, non raggiunge i livelli elevati del 2017 (come invece evidenziato dalle altre decomposizioni). Osservando gli istogrammi e il test di Bera-Jarque, si può escludere la decomposizione SEATS, mentre le altre due mantengono un comportamento abbastanza simile.

#### 4. Regressione

Dal momento che nella fase di modellistica, prenderemo in considerazione i modelli regARIMA, e il nostro dataset contiene alcune variabili che possono essere regredite sugli inquinanti di nostro interesse, conduciamo una regressione lineare, per capire le relazioni esistenti tra questi e tre variabili meteorologiche: le piogge cumulate, l'umidità relativa e la temperatura.

Si svolgeranno due diverse regressioni lineari, una per l'inquinante NO<sub>2</sub> e l'altra per l'inquinante PM<sub>10</sub>. Prima, però, di procedere, è opportuno capire quale modello possa essere più adatto, ad esempio se considerare tutte le variabili meteorologiche, se alcune sono non significative, o se alcune presentano forte collinearità.

Si procede, quindi, con l'analisi di scatterplot e correlazione tra le variabili di interesse.



Da questa matrice, emerge che tutte le correlazioni sono statisticamente molto significative, in particolare la *temperatura* è la variabile che ha una relazione più forte con entrambi gli inquinanti, con dei valori pari a -0.815 e -0.796, logici perché, come già espresso più volte in questo report, a temperature più basse ci si aspetta un maggior inquinamento, poiché l'aria fredda intrappola gli inquinanti per via dell'inversione termica e soprattutto comporta un maggior uso del riscaldamento domestico che causa più inquinamento. Inoltre, la linea blu (che mostra la regressione lineare) e la rossa (che indica la loess) sono quasi sovrapposte, segno di una buona relazione lineare.

In riferimento alla variabile *pioggia\_cum*, le correlazioni scendono a -0.306 e -0.498, ma sono entrambe statisticamente significative. Ci aspettavamo correlazioni negative, perché anche in questo caso, elevati livelli di pioggia, vanno a ridurre l'inquinamento, generando un effetto di pulizia dell'aria (tanto che precedentemente, avevamo riscontrato valori particolarmente alti e anomali di inquinante proprio nei mesi caratterizzati da totale assenza di pioggia). Anche in questo caso, la relazione sembra essere abbastanza lineare (anche se meno, se paragonata alla variabile temperatura), ma è una variabile che si comporta come previsto.

In ultimo, la variabile *umidita\_relativa* mostra una correlazione positiva di 0.502 e 0.407: l'umidità è maggiore quando c'è una minore temperatura, quindi ovviamente è correlata positivamente con l'inquinamento che raggiunge valori più elevati d'inverno, quando è presente molta nebbia. Dagli scatterplot, emerge che c'è sicuramente maggiore dispersione.

È fondamentale capire anche se c'è forte correlazione tra le variabili esplicative, perché bisogna evitare situazioni di multicollinearità:

- Temperatura e Umidità: mostrano una correlazione negativa pari a -0.631, che è la più forte; quindi, sarebbe preferibile rimuovere una tra queste due, perché altrimenti il modello non riesce a distinguere l'effetto di una variabile dall'altra.
- La pioggia cumulata invece ha una correlazione positiva sia con la temperatura (0.253), che con l'umidità (0.221), il che significa che possiamo tenere questa variabile.

L'ideale sarebbe rimuovere una tra temperatura ed umidità: considerando le relazioni con le variabili risposta, si preferisce mantenere senza dubbio la temperatura. Tutte queste conclusioni sono in realtà valide per entrambi gli inquinanti.

Quindi, da un'analisi preliminare si sceglie di omettere la variabile *umidita\_relativa*, ma per individuare il modello di regressione lineare migliore, costruiamo tre diversi modelli e utilizziamo le metriche di performance per individuare quale sia il modello migliore. I modelli che testiamo sono i seguenti, sia per l'inquinante NO<sub>2</sub> che per il PM<sub>10</sub>, dove con *T* si indica la temperatura, mentre con *P* indichiamo le piogge:

$$\begin{aligned} NO_2 &= \alpha_0 + \alpha_1 T + \alpha_2 P + \varepsilon_t & PM_{10} &= \alpha_0 + \alpha_1 T + \alpha_2 P + \varepsilon_t \\ NO_2 &= \beta_0 + \beta_1 T + \varepsilon_t & PM_{10} &= \beta_0 + \beta_1 T + \varepsilon_t \\ NO_2 &= \gamma_0 + \gamma_1 P + \varepsilon_t & PM_{10} &= \gamma_0 + \gamma_1 P + \varepsilon_t \end{aligned}$$

Andiamo a valutare le performance e scegliamo il modello migliore di regressione per ognuno dei due inquinanti.

### Inquinante NO<sub>2</sub>

I risultati sono i seguenti, da cui emerge che il modello migliore è il primo, con entrambe le variabili meteorologiche, perché ha valori più bassi di CV, AIC, AICc e BIC, mentre ha l' $R^2_{adj}$  che indica un adattamento ai dati del 67%.

| NO <sub>2</sub> | CV     | AIC    | AICc   | BIC    | R <sup>2</sup> <sub>Adj</sub> |
|-----------------|--------|--------|--------|--------|-------------------------------|
| M1              | 55.99  | 671.09 | 671.35 | 683.55 | 0.67                          |
| M2              | 57.36  | 674.49 | 674.64 | 683.83 | 0.66                          |
| M3              | 154.85 | 839.29 | 839.44 | 848.63 | 0.088                         |

```

Residuals:
    Min       1Q   Median       3Q      Max
-16.9573  -4.6570  -0.3408   4.6219  20.1614

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  46.359999    1.275312    36.35  <2e-16 ***
Temperatura  -1.274742    0.074672   -17.07  <2e-16 ***
Pioggia_cum  -0.021401    0.009225    -2.32   0.0216 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 7.437 on 163 degrees of freedom
Multiple R-squared:  0.6749,    Adjusted R-squared:  0.6709
F-statistic: 169.2 on 2 and 163 DF,  p-value: < 2.2e-16

```

I parametri del sono tutti statisticamente significativi ad un livello  $\alpha = 5\%$ , anche se il coefficiente associato alla variabile pioggia ha un p-value di 0.0216. L'intercetta ha un valore di 46.35: questo significa che, se la temperatura è pari a 0°C e le piogge sono assenti, il livello dell'inquinante è di 46.35, il che ha senso anche da un punto di vista interpretativo. Il coefficiente associato alla variabile *temperatura* è di -1.27: l'aumento di un grado Celsius, genera una diminuzione

dell'inquinamento dell'1.27μg/m<sup>3</sup>; il coefficiente associato alla variabile *pioggia\_cum* è -0.021, cioè se c'è un accumulo di pioggia di 1mm in più, il livello di inquinamento scende di 0.021μg/m<sup>3</sup>. Questi risultati sono perfettamente in linea con quanto ci aspettavamo, in termini di segno, perché come abbiamo ribadito più volte, livelli di inquinamento più elevati sono associati a temperature più basse e a situazione con minori piogge.

Possiamo rappresentare, inoltre, la distribuzione dei residui: in realtà, dal correlogramma emerge un'importante autocorrelazione, che sicuramente non ci permette di pensare ai residui come dei white noise, nonostante la loro distribuzione normale (rappresentata nell'istogramma). Anche l'andamento in realtà non sembra essere propriamente casuale attorno allo zero, perché ad esempio nella seconda metà rimane molto sotto questo valore.



## Inquinante PM<sub>10</sub>

Si sceglie il modello M1, che contiene entrambe le variabili esplicative: ha valori più bassi di CV, AIC, AICc e BIC, mentre ha l' $R^2_{adj}$  che indica un adattamento ai dati del 72%.

| $PM_{10}$ | CV     | AIC    | AICc   | BIC    | $R^2_{Adj}$ |
|-----------|--------|--------|--------|--------|-------------|
| M1        | 44.30  | 631.62 | 631.88 | 644.08 | 0.72        |
| M2        | 58.89  | 678.93 | 679.08 | 688.27 | 0.63        |
| M3        | 120.99 | 798.31 | 798.46 | 807.65 | 0.24        |

```
Residuals:
    Min       1Q   Median       3Q      Max
-12.8403  -4.3005  -0.2114   3.5997  20.8115


Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  48.863739    1.132363   43.152  < 2e-16 ***
Temperatura  -1.123828    0.066302  -16.950  < 2e-16 ***
Pioggia_cum  -0.061501    0.008191   -7.508  3.71e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.603 on 163 degrees of freedom
Multiple R-squared:  0.7278,    Adjusted R-squared:  0.7245
F-statistic: 217.9 on 2 and 163 DF,  p-value: < 2.2e-16
```

Osservando i parametri del modello, si può affermare che tutti i coefficienti sono statisticamente significativi. L'intercetta ha un valore di 48.86: se la temperatura è pari a 0°C e le piogge sono assenti, il particolato raggiunge un valore di 48.86 $\mu\text{g}/\text{m}^3$  (ha senso anche logicamente). Il coefficiente associato alla variabile *temperatura* è di -1.12: l'aumento di un grado Celsius, genera una diminuzione dell'inquinamento dell'1.12 $\mu\text{g}/\text{m}^3$ ; il coefficiente associato alla variabile

*pioggia\_cum* è -0.061, cioè se piove 1mm in più, il livello di inquinamento scende di 0.061 $\mu\text{g}/\text{m}^3$ . Così come per l' $\text{NO}_2$ , questi risultati sono perfettamente in linea con quanto ci aspettavamo, in termini di segno, perché come abbiamo ribadito più volte, livelli di inquinamento più elevati si presentano con temperature più basse e in situazioni con minori precipitazioni.

Anche per questa variabile, i residui nonostante abbiano una distribuzione normale, presentano una forte autocorrelazione che fa cadere l'ipotesi di distribuzione White Noise. Rispetto a prima, però l'andamento dei residui sembra essere più casuale.



## 5. Modellistica

In questa fase il nostro obiettivo è individuare il modello più adatto a rappresentare i nostri dati, individuando quali autocorrelazioni totale e parziale teoriche si avvicinano maggiormente a quelle campionarie. Si sfrutta, a tal proposito, la procedura di Box&Jenkins:

- Analisi grafica della serie, per capire se la serie è caratterizzata da un trend, stagionalità, outliers o eteroschedasticità, adottando trasformazioni di Box-Cox e differenziazioni se necessarie, dopo aver anche studiato le ACF e PACF (analisi di stazionarietà e stagionalità) e scelta del modello migliore
- Stimare i parametri di interesse del modello con il metodo della massima verosimiglianza

Quando abbiamo più modelli ARMA, si possono utilizzare gli indici AIC, AICc, BIC per valutare quale si adatta meglio ai dati.

Per tutte e quattro le serie storiche, si procede in primo luogo con una modellistica ARIMA che viene applicata ai residui delle serie destagionalizzata e detrendizzata, poi si procede con un modello SARIMA, dal momento che sono quattro serie stagionali e in ultimo con il regARIMA, dove si considera come

variabile di risposta gli inquinanti  $NO_2$  e  $PM_{10}$  e come regressori le serie originali *Temperatura*, *Pioggia\_cum*. Consideriamo tutti i modelli per ognuna delle singole serie storiche.

### 5.1. Modellistica per $NO_2$ a Bergamo

Il primo modello è l'**ARIMA**: quello che meglio identifica l'andamento della serie è un ARIMA (1,0,0), cioè un'AR (1), con un ordine della parte autoregressiva  $p = 1$ , stazionario ( $d = 0$ ) e senza media mobile ( $q = 0$ ). Il processo in forma estesa è il seguente:

$$Y_t = \mu + \phi Y_{t-1} + \varepsilon_t$$

Il processo è influenzato dal suo ritardo precedente, sempre invertibile, ed è stazionario perché ha un coefficiente pari a  $\phi_1 = 0.5562$ , che inoltre è statisticamente significativo (statistica test di 6.20).

```
ARIMA(1,0,0) with zero mean
Coefficients:
    ar1
    0.5562
s.e.    0.0897

sigma^2 = 27.76: log likelihood = -255.39
AIC=514.77 AICc=514.92 BIC=519.61
```

Proseguendo con la stima di un modello **SARIMA**, invece, dato che la serie è stagionale, l'applicazione di Box-Jenkins alla serie originale mi restituisce la moltiplicazione tra un'ARIMA (1,0,0) e un modello ARIMA (2,1,0) che cattura la stagionalità della serie. La sua equazione compatta è

$$(1 - \Phi_1 L^{12} - \Phi_2 L^{24})\phi_1(L)(1 - L^{12})Y_t = \varepsilon_t$$

I coefficienti in questo caso sono tutti statisticamente significativi e sono  $\phi_1 = 0.6001$  (test statistic: 6.060469),  $\Phi_1 = -0.5022$  (statistic test: -4.285684),  $\Phi_2 = -0.5022$  (statistic test: -4.545332).

```
ARIMA(1,0,0)(2,1,0)[12]
Coefficients:
    ar1    sar1    sar2
    0.6001 -0.5022 -0.5022
s.e.    0.0990  0.1172  0.1105

sigma^2 = 32.48: log likelihood = -227.19
AIC=462.39 AICc=462.99 BIC=471.44
```

In ultimo, stimiamo anche un modello **regARIMA**, dove la variabile risposta è la serie originale  $NO_2$  a Bergamo e i regressori sono le serie originali *Temperatura*, *Pioggia\_cum*. Si ottiene un modello di regressione lineare multipla con errori che si distribuiscono come un ARIMA (1,0,0), cioè un'AR (1), con una parte regressiva di ordine  $p = 1$ , stazionario se il coefficiente è in modulo inferiore a 1.

La regressione con errori ARIMA può essere scritta come:

$$NO_2 = \alpha_0 + \alpha_1 T + \alpha_2 P + \frac{1}{1 - \phi_1 L} \varepsilon_t$$

In questo caso, i coefficienti sono tutti statisticamente significativi e sono pari a  $\phi_1 = 0.6151$  (statistic test: 7.18),  $\alpha_0 = 51.7546$  (s.t.: 21.84),  $\alpha_1 = -1.3383$  (s.t.: -11.04),  $\alpha_2 = -0.0275$  (s.t.: -3.61). I valori degli ultimi tre coefficienti sono simili a quelli ottenuti nel modello di regressione completo, ma non sono uguali dal momento che sono stati stimati con il metodo della massima verosimiglianza.

```
Regression with ARIMA(1,0,0) errors
Coefficients:
    ar1 intercept Bergamo_Temperatura Bergamo_Piogge
    0.6151  51.7546        -1.3383        -0.0275
s.e.    0.0857    2.3703         0.1212         0.0076


sigma^2 = 28.03: log likelihood = -254.29
AIC=518.58 AICc=519.36 BIC=530.67
```

Nella seguente tabella, utilizzando i criteri di ottimizzazione, individuiamo nel modello **SARIMA** il migliore, dal momento che presenta valori molto bassi dei criteri AIC, AICc, BIC e valori elevati di  $R^2$ .


| <i><math>NO_2</math> Bergamo</i> | <i>AIC</i> | <i>AICc</i> | <i>BIC</i> | <i><math>R^2</math></i> |
|----------------------------------|------------|-------------|------------|-------------------------|
| <i>Regr. completa</i>            | 671.09     | 671.34      | 683.55     | 0.675                   |
| <i>ARIMA</i>                     | 514.77     | 514.92      | 519.61     | 0.071                   |
| <i>SARIMA</i>                    | 462.39     | 462.99      | 471.44     | 0.855                   |
| <i>regARIMA</i>                  | 518.58     | 519.36      | 530.67     | 0.852                   |

Procediamo ora con l'analisi delle innovazioni per vedere come si adatta il modello ai dati.

Nella rappresentazione seguente osserviamo l'andamento dei residui, l'istogramma, il box-plot, i lag plot e il grafico dell'autocorrelazione totale e parziale. I residui sembrano avere un andamento casuale attorno allo zero, con una distribuzione normale e simmetrica (come confermato dall'istogramma e dal box-plot). Inoltre, le autocorrelazioni sono tutte statisticamente non significative, collocate entro le bande di confidenza. Possiamo quindi concludere che i residui sono distribuiti come dei white noise. I primi 12 valori nulli sono in realtà una conseguenza della differenziazione.



Il modello sembra anche descrivere adeguatamente l'andamento della serie originale, coglie infatti i picchi positivi e negativi, tanto che ricordiamo presentava un valore dell' $R^2$  pari a 0.855, cioè, spiega l'85,5% della varianza totale, che è un valore molto elevato.



## 5.2. Modellistica per NO<sub>2</sub> a Malpensa

Il modello **ARIMA** che meglio identifica l'andamento della serie è un ARIMA (1,0,0), cioè un'AR (1), con un ordine della parte autoregressiva  $p = 1$ , stazionario ( $d = 0$ ) e senza media mobile ( $q = 0$ ). Il processo in forma estesa è il seguente:

$$Y_t = \mu + \phi Y_{t-1} + \varepsilon_t$$

Il processo è influenzato dal suo ritardo precedente, sempre invertibile, ed è stazionario perché ha un coefficiente pari a  $\phi_1 = 0.4067$ , che inoltre è statisticamente significativo (statistica test di 4.05).

```
ARIMA(1,0,0) with zero mean
Coefficients:
    ar1
    0.4067
s.e.  0.1002

sigma^2 = 12.48: log likelihood = -222.12
AIC=448.23 AICC=448.38 BIC=453.07
```

Quando si stima un modello **SARIMA**, invece, dato che la serie è stagionale, l'applicazione di Box-Jenkins alla serie originale mi restituisce la moltiplicazione tra un'ARIMA (1,0,0) e un modello ARIMA (0,1,1) che cattura la stagionalità della serie. La sua equazione compatta è

$$\phi_1(L)(1 - L^{12})Y_t = c + (1 - \theta_1 L^{12})\varepsilon_t$$

I coefficienti in questo caso sono tutti statisticamente significativi e sono  $\phi_1 = 0.3799$  (test statistic: 3.377633),  $\theta_1 = -0.4737$  (statistic test: -2.776342), e in ultimo il drift  $c = -0.1290$  (statistic test: -3.207313) che indica la presenza di un trend lineare nel modello.

```
ARIMA(1,0,0)(0,1,1)[12] with drift
Coefficients:
    ar1      sma1      drift
    0.3799  -0.4737  -0.1290
s.e.  0.1125   0.1706   0.0402

sigma^2 = 16.96: log likelihood = -201.3
AIC=410.61 AICC=411.21 BIC=419.66
```

In ultimo, il modello **regARIMA**, con variabile risposta la serie originale NO<sub>2</sub> a Malpensa e regressori le serie originali *Temperatura*, *Pioggia\_cum*. Si ottiene un modello di regressione lineare multipla con errori

che si distribuiscono come un ARIMA (3,1,1), cioè con parte regressiva di ordine  $p = 3$ , non stazionario ( $d = 1$ ), e con parte a media mobile di ordine pari a  $q = 1$ .

La regressione con errori ARIMA può essere scritta, differenziando ogni variabile (indicata con l'asterisco), come una regressione lineare con errori ARMA:


$$NO_2^* = \alpha_1 T^* + \alpha_2 P^* + \frac{\theta_1(L)}{\phi_3(L)} \varepsilon_t$$

In questo caso, i coefficienti sono pari a  $\phi_1 = 0.5943$  (statistic test: 5.0049),  $\phi_2 = 0.0084$  (statistic test: 0.0657),  $\phi_3 = -0.2849$  (statistic test: -2.61),  $\theta_1 = -0.9033$  (s.t.: -20.9),  $\alpha_1 = -1.1501$  (s.t.: -9.256),  $\alpha_2 = -0.0165$  (s.t.: -2.10) e, ad eccezione di  $\phi_2$  sono tutti statisticamente significativi. I valori degli ultimi due coefficienti sono simili a quelli ottenuti nel modello di regressione completo, ma non sono uguali dal momento che sono stati stimati con il metodo della massima verosimiglianza.


| Regression with ARIMA(3,1,1) errors      |        |        |         |         |                      |                  |
|------------------------------------------|--------|--------|---------|---------|----------------------|------------------|
| Coefficients:                            |        |        |         |         |                      |                  |
|                                          | ar1    | ar2    | ar3     | ma1     | Malpensa_Temperatura | Malpensa_Pioggie |
| s.e.                                     | 0.5943 | 0.0084 | -0.2849 | -0.9033 | -1.1501              | -0.0165          |
|                                          | 0.1187 | 0.1284 | 0.1092  | 0.0432  | 0.1242               | 0.0078           |
| sigma^2 = 20.82; log likelihood = -238.5 |        |        |         |         |                      |                  |
| AIC=490.99 AICc=492.51 BIC=507.84        |        |        |         |         |                      |                  |

Dalla seguente tabella, confrontando i criteri, emerge che il modello migliore è il **SARIMA**, per cui si procederà a calcolare le innovazioni e verificare come il modello si adatta ai dati.

| <i>NO<sub>2</sub> Malpensa</i> | <i>AIC</i> | <i>AICc</i> | <i>BIC</i> | <i>R<sup>2</sup></i> |
|--------------------------------|------------|-------------|------------|----------------------|
| <i>Regr. completa</i>          | 671.09     | 671.34      | 683.55     | 0.675                |
| <i>ARIMA</i>                   | 448.23     | 448.38      | 453.07     | 0.021                |
| <i>SARIMA</i>                  | 410.61     | 411.21      | 419.66     | 0.917                |
| <i>regARIMA</i>                | 490.99     | 492.51      | 507.84     | 0.872                |



I residui sembrano, fino al 2022 escluso, avere un andamento più o meno casuale attorno allo zero, ma dal 2022 in avanti sono ben sopra questo valore, infatti anche la distribuzione è abbastanza normale, ma la



Kernel non coincide perfettamente con la curva teorica. Invece, i correlogrammi parziali e totali danno buoni risultati in termini di incorrelazione, così come i lagplot che sono abbastanza sferici.

Guardando i valori fittati, e confrontandoli con la serie originale, si può comunque notare come colga abbastanza bene l'andamento: ricordiamo che l'indice  $R^2$  aveva un valore del 91%, cioè il modello spiega più del 91% della varianza totale.

### 5.3. Modellistica per PM<sub>10</sub> a Bergamo

Utilizzando gli **ARIMA**, l'output mi restituisce come modello che meglio identifica l'andamento della serie un white noise con media zero. Si può rappresentare come segue:

$$Y_t = \varepsilon_t$$

ARIMA(0,0,0) with zero mean

sigma^2 = 38.86: log likelihood = -269.66  
AIC=541.33 AICc=541.38 BIC=543.75

Utilizzando i **SARIMA**, dato che la serie è stagionale, si ha la moltiplicazione tra un'ARIMA (0,0,0) e un modello ARIMA (2,1,0) che cattura la stagionalità della serie, con un drift. La sua equazione compatta è

$$(1 - \Phi_1 L^{12} - \Phi_2 L^{24})(1 - L^{12})Y_t = c + \varepsilon_t$$

I coefficienti in questo caso sono tutti statisticamente significativi e sono il drift  $c = -0.1098$  (test statistic: -2.83),  $\Phi_1 = -0.7891$  (statistic test: -6.55),  $\Phi_2 = -0.4190$  (statistic test: -3.36).

ARIMA(0,0,0)(2,1,0)[12] with drift

Coefficients:

|      | sar1    | sar2    | drift   |
|------|---------|---------|---------|
|      | -0.7891 | -0.4190 | -0.1098 |
| s.e. | 0.1203  | 0.1245  | 0.0387  |

sigma^2 = 57.33: log likelihood = -247.48  
AIC=502.96 AICc=503.57 BIC=512.01

Stimando un modello **regARIMA**, dove la variabile risposta è la serie originale  $PM_{10}$  a Bergamo e i regressori sono le serie originali *Temperatura*, *Pioggia\_cum*, si ottiene un modello di regressione lineare multipla con errori che si distribuiscono come un ARIMA (0,1,1), cioè un'MA (1), con una parte a media mobile di ordine  $q = 1$ , e non stazionario.

La regressione con errori ARIMA può essere scritta, differenziando ogni variabile, come:

$$PM_{10}^* = \alpha_1 T^* + \alpha_2 P^* + \theta_1(L)\varepsilon_t$$

In questo caso, i coefficienti sono tutti statisticamente significativi e sono pari a  $\theta_1 = -0.8922$  (statistic test: -20.68),  $\alpha_1 = -1.0353$  (s.t.: -11.84),  $\alpha_2 = -0.0674$  (s.t.: -6.74). I valori degli ultimi due coefficienti sono simili a quelli ottenuti nel modello di regressione completo, ma non sono uguali dal momento che sono stati stimati con il metodo della massima verosimiglianza.

Regression with ARIMA(0,1,1) errors

Coefficients:


|      | ma1     | Bergamo_Temperatura | Bergamo_Pioggie |
|------|---------|---------------------|-----------------|
|      | -0.8922 | -1.0353             | -0.0674         |
| s.e. | 0.0431  | 0.0874              | 0.0100          |


sigma^2 = 38.73: log likelihood = -265.54  
AIC=539.08 AICc=539.6 BIC=548.71

Dal confronto tra i modelli, il migliore sembrerebbe essere il SARIMA: nonostante il regARIMA ha un  $R^2$  più elevato, utilizzando gli altri tre criteri, c'è uno scostamento molto evidente. Si procede, quindi con l'analisi delle innovazioni in riferimento al modello SARIMA.

| <i>PM<sub>10</sub> Bergamo</i> | <i>AIC</i> | <i>AICc</i> | <i>BIC</i> | <i>R<sup>2</sup></i> |
|--------------------------------|------------|-------------|------------|----------------------|
| <i>Regr. completa</i>          | 631.62     | 631.88      | 644.08     | 0.728                |
| <i>ARIMA</i>                   | 541.33     | 541.38      | 543.75     | // (WN)              |
| <i>SARIMA</i>                  | 502.96     | 503.57      | 512.01     | 0.717                |
| <i>regARIMA</i>                | 539.08     | 539.6       | 548.71     | 0.769                |

I residui sembrano avere un andamento casuale attorno allo zero, con una distribuzione normale e simmetrica (come confermato dall'istogramma e dal box-plot). I correlogrammi parziali e totali mostrano autocorrelazioni statisticamente non significative, collocate entro le bande di confidenza. Possiamo quindi concludere che i residui sono distribuiti come dei white noise. Il modello sembra anche descrivere adeguatamente l'andamento della serie originale, coglie infatti i picchi positivi e negativi, tanto che ricordiamo presentava un valore dell' $R^2$  pari a 0.717, cioè spiega quasi il 72% della varianza totale, che è un valore molto elevato.





#### 5.4. Modellistica per PM<sub>10</sub> a Malpensa

Utilizzando gli **ARIMA**, anche in questo caso l'output mi restituisce come modello che meglio identifica l'andamento della serie un white noise con media zero. Si può rappresentare come segue:

$$Y_t = \varepsilon_t$$

ARIMA(0,0,0) with zero mean

sigma^2 = 35.02: log likelihood = -265.34  
AIC=532.69 AICc=532.74 BIC=535.11

Proseguendo con la stima di un modello **SARIMA**, invece, dato che la serie è stagionale, l'applicazione di Box-Jenkins alla serie originale mi restituisce la moltiplicazione tra un white noise e un modello ARIMA(2,1,0) che cattura la stagionalità della serie. La sua equazione compatta è

$$(1 - \Phi_1 L^{12} - \Phi_2 L^{24})(1 - L^{12})Y_t = \varepsilon_t$$

I coefficienti in questo caso sono tutti statisticamente significativi e sono  $\Phi_1 = -0.7249$  (statistic test: -6.09),  $\Phi_2 = -0.3689$  (statistic test: -2.81).

ARIMA(0,0,0)(2,1,0)[12]

Coefficients:

    sar1    sar2  
    -0.7249  -0.3689  
s.e.    0.1190  0.1312

sigma^2 = 52.25: log likelihood = -243.9  
AIC=493.8  AICc=494.16  BIC=500.59

Infine, stimiamo anche un modello **regARIMA**, dove la variabile risposta è la serie originale *PM<sub>10</sub>* a Malpensa e i regressori sono le serie originali *Temperatura*, *Pioggia\_cum*. Si ottiene un modello di regressione lineare multipla con errori che si distribuiscono come un white noise.

La regressione con errori ARIMA può essere scritta come:

$$PM_{10} = \alpha_0 + \alpha_1 T + \alpha_2 P + \varepsilon_t$$

In questo caso, i coefficienti sono tutti statisticamente significativi e sono pari a  $\alpha_0 = 49.1959$  (s.t.: 35.08),  $\alpha_1 = -1.2130$  (s.t.: -14.93),  $\alpha_2 = -0.0763$  (s.t.: -6.75). I valori degli ultimi tre coefficienti sono simili a quelli ottenuti nel modello di regressione completo, ma non sono uguali dal momento che sono stati stimati con il metodo della massima verosimiglianza.

Regression with ARIMA(0,0,0) errors

Coefficients:


    intercept  Malpensa\_Temperatura  Malpensa\_Pioggie  
    49.1959                          -1.2130                  -0.0763  
s.e.    1.4023                          0.0813                  0.0113

sigma^2 = 34.91: log likelihood = -263.69  
AIC=535.37  AICc=535.89  BIC=545.05


Dalla tabella delle metriche presentata di seguito, il miglior modello per i primi tre criteri (AIC, AICc, BIC) è il SARIMA, mentre osservando l' $R^2$  si potrebbe optare per il regARIMA, che ha un elevato valore di  $R^2$ , segno che i regressori spiegano bene il comportamento dell'inquinamento. In realtà, però, i valori di  $R^2$  sono molto vicini (però non sono aggiustati), mentre gli altri tre criteri sembrano avere scostamenti più elevati. Si opta quindi per il modello **SARIMA**, così come per tutte le altre serie storiche, segno che per queste, la componente stagionale è di fondamentale importanza. Effettuata la scelta, si può procedere con

l'analisi delle innovazioni e la rappresentazione dei valori fittati sulla serie storica originale, per studiare l'adattamento del modello ai dati.

| <i>PM<sub>10</sub> Malpensa</i> | <i>AIC</i> | <i>AICc</i> | <i>BIC</i> | <i>R<sup>2</sup></i> |
|---------------------------------|------------|-------------|------------|----------------------|
| <i>Regr. completa</i>           | 631.62     | 631.88      | 644.08     | 0.728                |
| <i>ARIMA</i>                    | 532.69     | 532.74      | 535.11     | // (WN)              |
| <i>SARIMA</i>                   | 493.8      | 494.16      | 500.59     | 0.733                |
| <i>regARIMA</i>                 | 535.37     | 535.89      | 545.05     | 0.786                |



Tranne per il biennio 2018-2019, i residui sembrano avere abbastanza un andamento casuale attorno allo zero, sono simmetrici, e seguono abbastanza una distribuzione normale, anche se la coda a destra non è molto lineare. In compenso, i correlogramma parziale e totale mi restituiscono assenza di correlazione tra i residui. Inoltre, il modello segue le oscillazioni stagionali della serie storica, ma tende a sovrastimare i picchi del 2018 e 2019, e sottostimare quelli del 2021 e 2022.



## 6. Conclusione

In questo report, l'obiettivo era capire se vi fossero differenze in termini di inquinamento tra le due centraline e se in particolare la presenza di un aeroporto, con le emissioni dei voli e il relativo traffico indotto possa essere indice di un maggiore inquinamento. In realtà, dalle analisi svolte sembra che, innanzitutto, gli inquinanti sia fortemente stagionali, e questo emerge anche dalla fase di modellistica finale, dove per tutte e quattro le serie storiche abbiamo optato per un modello SARIMA, che potesse catturare al meglio l'andamento dell' $\text{NO}_2$  e del  $\text{PM}_{10}$  sia nei pressi di Malpensa, che nei pressi di Bergamo Città. Tuttavia, non sembrano esserci grandi differenze tra le due aree, soprattutto perché l'aeroporto è comunque dislocato dal centro città e raggiunge livelli di inquinamento quasi simili (se non addirittura in alcuni casi inferiori) a quelli tipici di un centro città come Bergamo: è sufficiente osservare come per l' $\text{NO}_2$  c'è un calo dei valori dell'inquinamento con il passare degli anni.

Inoltre, abbiamo visto come ci sia un forte legame tra gli inquinanti e le variabili metereologiche, soprattutto con la temperatura, come in realtà ci aspettavamo, infatti alcuni valori particolarmente alti, o bassi, delle serie storiche trovavano riscontro proprio in valori anomali della temperatura o delle piogge (ricordiamo mesi in cui le precipitazioni sono state nulle, comportando elevati valori di inquinamento). Questi risultati vengono anche poi evidenziati dalla regressione svolta.

Abbiamo anche osservato che il particolato non ha subito grandi cambiamenti durante la pandemia da COVID e le relative restrizioni: l' $\text{NO}_2$ , invece, sì. La motivazione principale è che il biossido di azoto è legato principalmente al traffico veicolare, quindi ha subito un importante crollo come evidenziato dai break strutturali nel momento in cui sono state introdotte misure restrittive che hanno generato un blocco del traffico e degli spostamenti.

In particolare, dalla fase di modellistica possiamo osservare che per tutte e quattro le serie storiche abbiamo sempre ottenuto una buona percentuale di adattamento ai dati, oltre il 65%, per tutti i modelli, tranne per gli ARIMA: è logico, se si pensa al fatto che esclude la componente stagionale che, invece, abbiamo visto essere essenziale proprio perché il livello di inquinamento è influenzato proprio dalle stagioni e dalle condizioni metereologiche ad esse associate.